参赛承诺书

提交包含此承诺书的 PDF 文件，表明所有此文件的作者共同承诺：

我们完全清楚，在竞赛开始后参赛队员不能以任何方式，包括电话、电子邮件、” 贴吧”、QQ 群、微信群等，与队外的任何人（包括指导教师）交流、讨论与赛题有关的问题；无论主动参与讨论还是被动接收讨论信息都是严重违反竞赛纪律的行为。

我们以中国大学生名誉和诚信郑重承诺，严格遵守竞赛章程和参赛规则，以保证竞赛的公正、公平性。如有违反竞赛章程和参赛规则的行为，我们将受到严肃处理。

我们授权北京理工大学数学建模竞赛组织方，可将我们的论文以任何形式进行公开展示（包括进行网上公示，在书籍、期刊和其他媒体进行正式或非正式发表等）。

2026 年 3 月

基于多源脉冲特征融合与双模型分类的电火花加工工艺参数优化研究

摘要：针对电火花加工（EDM）过程中关键控制变量工作液流量（DFlow）与放电间隙（DGap）的量化关系识别、协同调控简化以及最优参数预测三个核心问题，本文基于 154 组加工样本和 16 个脉冲特征参数，建立了”统计分析—协同建模—分类预测”三层次一体化建模框架。

在量化关系分析方面，综合采用 Pearson 相关分析、随机森林特征重要性评估、主成分分析（PCA）与线性判别分析（LDA）四种方法，多角度刻画脉冲特征对控制变量的影响机制。结果表明：DGap 与 CSM_C_MeanT（$r = 0.6693$）、BSM_B_MeanT（$r = -0.6434$）、CLM_C_MeanT（$r = 0.6302$）的线性相关性最强；DFlow 与 BSD_B_SDevT（$r = 0.4640$）、CLM_C_MeanT（$r = 0.4508$）、CSD_C_SDevT（$r = 0.4388$）的相关性最强。随机森林重要性分析进一步表明，DGap 的核心判别特征为 CSM_C_MeanT（14.91%）、BSM_B_MeanT（11.25%）和 ILD_I_SDevT（8.82%），DFlow 的核心判别特征为 ASM_A_MeanT（13.67%）与 ALM_A_MeanT（13.09%）。PCA 降维分析显示，前三个主成分累计解释方差达 78.07%，具有较强信息浓缩能力。

在协同调控方面，通过卡方独立性检验（$\chi^2 = 24.734$，$p < 0.001$）验证了 DFlow 与 DGap 的结构性关联，并定义复合控制指标 $S = DFlow + DGap$，Kruskal–Wallis 检验表明 16 个脉冲特征对 S 均达到显著水平，据此提出”一级确定复合档位、二级单变量执行”的协同调控方案。

在预测模型方面，比较随机森林、RBF 核支持向量机、k 近邻、LDA 和 Logistic 回归五类模型，以宏平均 F1 为核心评价指标进行 5 折交叉验证。最终确立”双模型并行预测”策略：DFlow 采用随机森林，Macro-F1 达 89.02%；DGap 采用 RBF 核 SVM，Macro-F1 达 70.55%。

关键词：电火花加工；脉冲特征；特征重要性；协同调控；随机森林；支持向量机

1 问题背景与重述

电火花加工（Electrical Discharge Machining，EDM）是现代精密制造领域中一种典型的特种加工工艺。其基本原理是：在工具电极与被加工工件之间施加脉冲电压，当极间电压超过某一阈值时，绝缘的工作液被击穿，产生局部瞬时高温放电通道（温度可达 8000~12000℃），从而在工件表面蚀除材料，实现高精度微细结构的成形加工。与传统机械切削相比，EDM 加工具有不受工件硬度限制、加工应力小、可实现复杂曲面成形等突出优点，在模具制造、航空航天精密零部件加工中被广泛应用。

在电火花加工过程中，放电参数的实时调控对加工质量与效率起决定性作用。其中，工作液流量（DFlow）与放电间隙（DGap）是两个最关键的在线控制变量：工作液流量直接影响极间冷却效果、蚀除产物排出能力以及放电稳定性；放电间隙则决定了放电能量密度与加工精度的平衡关系。在生产实践中，两个变量通常需要操作员根据加工状态同步调整，操控逻辑复杂，对工人经验依赖性较高，且存在因误操作导致短路、断弧或加工不稳定等风险。

题目提供了某研究机构在电火花加工过程中采集的 154 组加工数据，包含 16 个脉冲特征参数（涵盖 A、B、C、I 四类脉冲的均值时间特征与标准差时间特征、负载均值与标准差共 8 组双特征）以及两个离散型控制变量 DFlow 和 DGap，其取值均为 $\{-1, 0, +1\}$ 三个等级，分别对应” 减小/偏低、保持/中性、增大/偏高” 三种调节方向。围绕这一数据集，本文需回答以下三个问题：

(1) 分析 16 个脉冲特征参数与 DFlow、DGap 之间存在怎样的量化关系，并评估各特征对两个控制变量的影响大小；

(2) 分析 DFlow 与 DGap 两个控制变量之间的关系，讨论是否存在协同调控方案，以便在保证加工质量的前提下简化操作人员的工作流程；

(3) 根据给定的脉冲特征参数，建立数学模型预测最优的 DFlow 和 DGap 设定值，说明模型合理性，并讨论实际应用中需要考虑的因素。

结合问题结构，本文将研究划分为” 特征关系识别—控制量协同建模—最优参数预测” 三个递进层次依次展开，总体技术路线如图1所示。

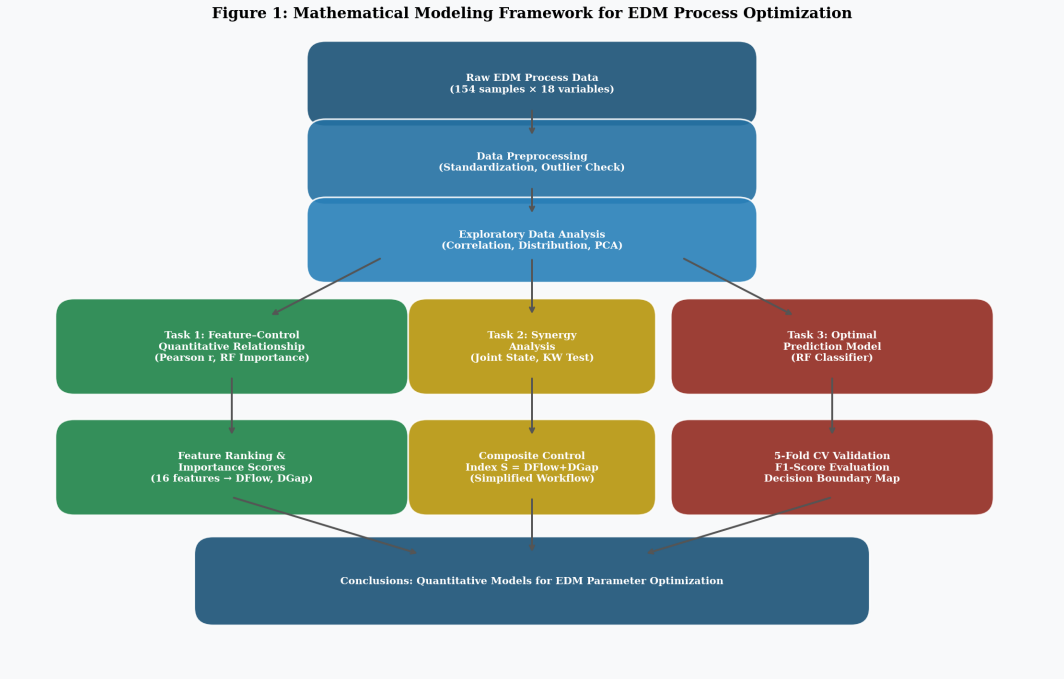


图 1 总体建模技术路线图。图中从原始数据出发，经数据预处理与探索性分析后，分三条并行支路分别解决问题一（特征关系量化）、问题二（协同调控）和问题三（预测模型），最终汇总于结论。

如图1所示，问题一的核心工作是建立脉冲特征与控制变量之间的定量映射，采用线性统计方法（Pearson 相关）和非线性评估方法（随机森林特征重要性）双线索并行；问题二的核心是揭示 DFlow 与 DGap 的联合统计规律并构造可操作的协同调控指标；问题三则通过多模型比较与交叉验证确定最优预测模型组合。三个问题之间具有递进性：问题一的特征重要性排序为问题三的建模奠定特征选择基础，问题二的联合状态分析则为问题三的模型结构选择提供先验依据。

2 符号说明

本文涉及的主要数学符号与统计量定义见表1。

表 1 主要符号及说明

符号	含义
$n = 154$	样本总数
$p = 16$	脉冲特征维数
$X = (x_1, x_2, \ldots, x_{16}) \in \mathbb{R}^p$	16 维脉冲特征向量
$y_f \in \{-1, 0, +1\}$	工作液流量控制变量（DFlow）
$y_g \in \{-1, 0, +1\}$	放电间隙控制变量（DGap）
$r_{x_j,y}$	第 j 个特征与控制变量 y 之间的 Pearson 相关系数
$I_j^{(f)}, I_j^{(g)}$	特征 x_j 对 DFlow、DGap 的随机森林重要性
$S = y_f + y_g$	复合控制指标，取值为 $\{-2, -1, 0, 1, 2\}$
H	Kruskal–Wallis 检验统计量
χ^2	卡方独立性检验统计量
P_k, R_k	第 k 类的精确率（Precision）与召回率（Recall）
F_1^{macro}	宏平均 F1 分数
$\hat{y}_f, \hat{y}_g$	模型对 DFlow、DGap 的预测值

3 问题分析

3.1 问题的数学抽象

从数学建模角度来看，本题的三个问题具有不同的本质特征，需要采用不同的方法论框架。

问题一属于**统计关系识别问题**。给定样本矩阵 $\boldsymbol{X} \in \mathbb{R}^{n\times p}$ 和离散响应向量 $\boldsymbol{y}_f, \boldsymbol{y}_g \in \{-1, 0, +1\}^n$，目标是量化每个特征 x_j 对 y_f 或 y_g 的边际贡献与综合贡献。这里存在两个挑战：其一，x_j 与 y 之间的关系未必是线性的，单纯依靠 Pearson 相关系数可能低估非线性贡献；其二，16 个特征之间存在较强共线性（如 BSM_B_MeanT 与 CSM_C_MeanT 之间的相关系数高达 -0.9438），单特征分析无法反映特征间的交互信息。因此，需要综合线性与非线性两类方法进行交叉验证。

问题二属于**联合分布与调控简化问题**。其核心是：在给定 $\boldsymbol{y}_f$ 和 $\boldsymbol{y}_g$ 均为离散类别变量的条件下，判断二者是否存在统计依赖关系，以及这种依赖关系能否支撑一个降维的、可操作的协同控制方案。值得注意的是，依赖关系既可以是线性的（相关），也可以是非线性的（联合分布结构），因此需同时考察相关系数检验与列联表独立性检验。

问题三属于**有监督三分类预测问题**。特别地，DFlow 在三个类别上的样本分布极为不均衡（类别 -1 仅 5 个样本，类别 0 有 128 个，类别 $+1$ 有 21 个），这导致常规的准确率指标失效，需引入对类别不均衡鲁棒的 Macro-F1 指标；同时，样本量有限（$n = 154$）且特征维度相对较高（$p = 16$），需注意过拟合风险，应通过交叉验证评估模型的泛化性能。

3.2 方法选择的依据

基于上述分析，本文按照如下逻辑选取分析方法：

(1) 用 **Pearson 相关分析**提供线性关系的基准度量，并通过显著性检验确认有效特征；

(2) 用**随机森林特征重要性**弥补线性方法的不足，捕获非线性贡献与特征交互效应，并通过节点纯度增益提供可解释的重要性排序；

(3) 用 **PCA** 消除共线性干扰、发现数据的主要变化方向，并通过低维散点图直观评估类别可分性；

(4) 用 **LDA** 明确各类别在最优判别方向上的分离程度，作为特征表达能力的直接验证；

(5) 用**卡方检验与 Kruskal–Wallis 检验**分别从列联表独立性和特征分布差异两个角度支撑协同调控的统计依据；

(6) 用 **5 折交叉验证的 Macro-F1** 作为最终预测模型的选择准则，兼顾性能与泛化稳定性。

4 模型假设

为保证建模的可实施性与结论的有效解释范围，本文作如下合理假设：

(1) **数据独立性假设**：154 个样本来源于相同类型的加工场景，各样本之间相互独立，不存在时序依赖或批次效应。需要指出的是，EDM 实际上是一个强时间依赖的动态物理过程，此假设系对现实的合理简化，其局限性将在第8节的展望中进一步讨论；

(2) **特征充分性假设**：16 个脉冲特征参数已能够有效表征加工过程中的主要放电状态，测量误差相对于特征变化幅度可忽略不计；

(3) **类别编码一致性假设**：DFlow 与 DGap 的取值 $\{-1, 0, +1\}$ 分别对应” 减小/低、保持/中、增大/高” 三种离散控制状态，且编码方向在所有样本中保持一致；

(4) **稳态加工假设**：每组样本均采集自加工状态相对稳定的时刻，不包含加工启动、停机或显著异常放电的瞬态数据；

(5) **专家操作最优性假设**：本文将数据集中给定的 154 组操作标签视为资深工程师或成熟数控系统在长期加工实践中沉淀的” 专家操作轨迹”。因此，” 最优参数预测” 问题被转化为” 基于专家历史策略的监督分类学习” 问题，即模型分类准确率越高，

越能复现乃至超越人类专家的协同调控能力。在此假设前提下，模型性能的上限受制于历史数据本身的质量与多样性；

(6) **模型适用范围假设**：本文所建模型适用于与数据来源相同或相近的加工工况，不直接外推至材料、电极类型或加工参数差异显著的工况。

5 数据预处理与探索性分析

5.1 数据集结构与类别分布

数据集共包含 154 个样本和 18 个字段，其中 16 个为脉冲特征输入变量，2 个为离散控制变量输出。16 个特征按放电脉冲类型（A、B、C、I 四类）和特征属性（均值时间特征、标准差时间特征、负载均值特征、负载标准差特征）组织，形成 $4 \times 4 = 16$ 个维度的特征矩阵。

两个控制变量的类别分布情况见表2。

表 2 数据集两个控制变量的类别分布统计

变量	物理意义	类别 -1	类别 0	类别 $+1$	总样本数	分布特征
DFlow	工作液流量	5（3.2%）	128（83.1%）	21（13.6%）	154	极度不均衡
DGap	放电间隙	33（21.4%）	86（55.8%）	35（22.7%）	154	相对均衡

由表2可以发现两个重要规律：第一，DFlow 在类别 0 上的占比高达 83.1%，意味着在当前数据对应的加工条件下，绝大多数时刻系统工作液流量处于中性状态，极少数样本属于流量增大（13.6%）或减小（3.2%）的状态，这种严重的类别不均衡将直接影响后续分类模型的训练与评估策略；第二，DGap 的分布较为均衡，三类样本数量相差不超过三倍，表明在数据采集的实验工况下，放电间隙的调节行为更为活跃多样。

上述分布差异也在一定程度上反映了两个控制变量的物理特性：放电间隙通常需要根据极间状态频繁、精细地调整，而工作液流量的调节更多依赖宏观工况判断，单次调节后往往维持较长时间，因此中性状态的占比更高。这一物理解释支持了数据分布的合理性，同时也说明对两个变量应采用不同评估体系。

5.2 脉冲特征描述性统计

16 个脉冲特征的完整描述性统计结果见表3。

表 3 16 个脉冲特征的描述性统计

特征名称	均值	标准差	最小值	最大值
ASM_A_MeanT	−4.656	0.111	−4.960	−4.380
ASD_A_SDevT	0.070	0.066	0.000	0.390
BSM_B_MeanT	0.816	0.328	0.040	1.140
BSD_B_SDevT	0.115	0.112	0.000	0.450
CSM_C_MeanT	5.462	0.313	5.100	6.100
CSD_C_SDevT	0.108	0.101	0.000	0.380
ISM_I_MeanT	2.188	0.546	0.810	2.910
ISD_I_SDevT	0.230	0.188	0.000	0.770
ALM_A_MeanT	−4.653	0.077	−4.850	−4.500
ALD_A_SDevT	0.097	0.054	0.010	0.260
BLM_B_MeanT	0.843	0.258	0.270	1.140
BLD_B_SDevT	0.199	0.133	0.000	0.470
CLM_C_MeanT	5.454	0.258	5.120	5.870
CLD_C_SDevT	0.188	0.110	0.000	0.370
ILM_I_MeanT	2.260	0.394	1.070	2.790
ILD_I_SDevT	0.396	0.211	0.030	0.940

从表3可以归纳出若干规律性特征。首先，ASM_A_MeanT（均值约 −4.656）与 ALM_A_MeanT（均值约 −4.653）的数值分布高度相似，标准差分别仅为 0.111 和 0.077，说明 A 类脉冲的时间特征与负载时间特征在整体尺度上接近且波动较小，反映了 A 类放电脉冲时间较为稳定。其次，BSM_B_MeanT 与 BLM_B_MeanT（均值分别为 0.816 和 0.843）、CSM_C_MeanT 与 CLM_C_MeanT（均值分别为 5.462 和 5.454）均表现出相近的均值，但标准差明显较大，说明 B 类和 C 类脉冲特征在不同加工状态下具有更大的变异范围。此外，标准差类特征（如 BSD、CSD、ILD 等）普遍存在较大的变异系数，暗示放电过程的时间波动性在不同状态下差异显著，这类特征可能对控制变量具有较强的区分能力。

5.3 数据整体分布的可视化分析

图2从类别分布饼图、DFlow–DGap 联合频次热图以及各特征分 DGap 类别的小提琴图三个维度，对数据集进行了全面的可视化呈现。

Figure 2: Dataset Overview — Class Distributions and Feature Distributions by DGap

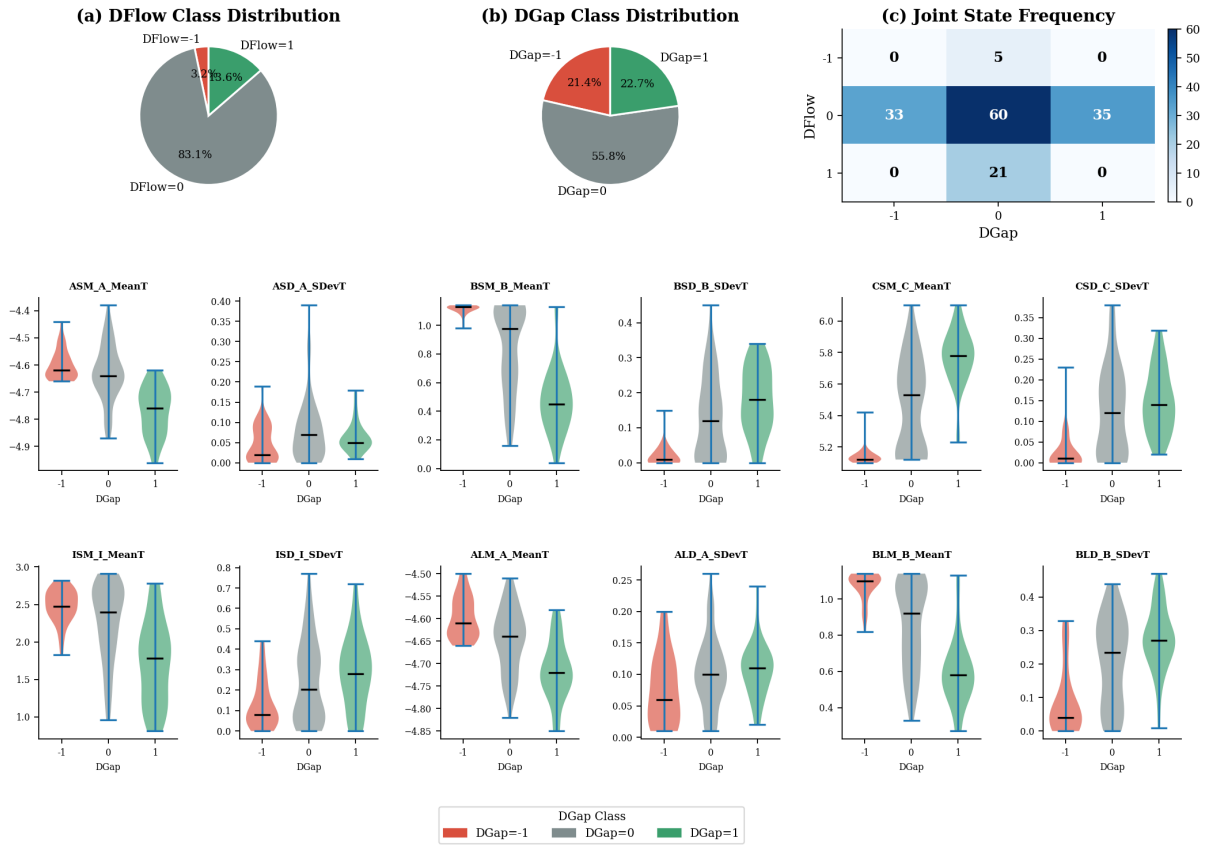


图 2 数据集总体分布与特征分布可视化。图 (a) 与图 (b) 分别展示 DFlow 和 DGap 的类别分布饼图；图 (c) 给出 DFlow–DGap 联合频次热图；图 (d) 至图 (s) 为 16 个特征按 DGap 三类分组的小提琴图，红色、灰色、绿色分别对应 $DGap = -1, 0, +1$ 三类。

从图2的小提琴图中可以直观观察到：CSM_C_MeanT、BSM_B_MeanT、CLM_C_MeanT、BLM_B_MeanT 等特征在三类 DGap 状态下的分布差异最为显著，三条小提琴图的形态和中位数位置均存在明显偏移，说明这些特征具有较强的 DGap 区分能力；而 ASD_A_SDevT 等特征在三类状态下的分布几乎完全重叠，说明其对 DGap 的判别贡献有限。这些初步观察与后续定量分析的结论保持一致，为后续特征重要性评估提供了直观的先验支撑。

联合频次热图（图 (c)）进一步表明，DFlow 类别 0 与 DGap 所有类别的组合在频次上均远高于 DFlow 类别 ± 1 的情形，其中 $(DFlow = 0, DGap = 0)$ 组合出现频次最高，达 60 次。这一不均衡的联合分布揭示了数据采集工况的内在规律，也是后续协同调控分析的关键起点。

在数据标准化处理上，所有特征均进行 z-score 标准化：

$$\tilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \tag{1}$$

其中 $\bar{x}_j$ 为第 j 个特征的样本均值，s_j 为其样本标准差。标准化消除了不同特征量纲差异的影响，保证后续 PCA、LDA 和分类模型的计算结果不受特征尺度干扰。

6 问题一：脉冲特征与控制变量的量化关系分析

6.1 Pearson 线性相关分析

6.1.1 模型建立

Pearson 相关系数是衡量两个随机变量之间线性相关程度的经典统计量。对于第 j 个脉冲特征 x_j 与控制变量 y（DFlow 或 DGap），其 Pearson 相关系数定义为：

$$r_{x_j,y} = \frac{\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)^2} \cdot \sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}, \tag{2}$$

其中 $\bar{x}_j$ 与 $\bar{y}$ 分别为对应变量的样本均值，$r_{x_j,y} \in [-1, 1]$。当 $|r|$ 趋近于 1 时，表示两变量之间存在强线性相关；$|r|$ 趋近于 0 时，表示线性关系微弱。为判断相关系数的统计显著性，构造 t 统计量：

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t(n-2), \tag{3}$$

在显著性水平 $\alpha = 0.05$ 下对所有特征进行双侧检验。

6.1.2 分析结果

全部 16 个特征与两个控制变量的完整 Pearson 相关系数见表4。

表 4 16 个脉冲特征与 DFlow、DGap 的 Pearson 相关系数

特征名称	r（DFlow）	r（DGap）
ASM_A_MeanT	-0.0541	-0.5068^{***}
ASD_A_SDevT	0.4234^{***}	0.0733
BSM_B_MeanT	-0.2592^{**}	-0.6434^{***}
BSD_B_SDevT	0.4640^{***}	0.4723^{***}
CSM_C_MeanT	0.3066^{***}	0.6693^{***}
CSD_C_SDevT	0.4388^{***}	0.4073^{***}
ISM_I_MeanT	0.0326	-0.4624^{***}
ISD_I_SDevT	0.3266^{***}	0.2750^{***}
ALM_A_MeanT	-0.2391^{**}	-0.5202^{***}
ALD_A_SDevT	0.2319^{**}	0.1906^{*}
BLM_B_MeanT	-0.3751^{***}	-0.6200^{***}
BLD_B_SDevT	0.3265^{***}	0.4626^{***}
CLM_C_MeanT	0.4508^{***}	0.6302^{***}
CLD_C_SDevT	0.3102^{***}	0.4000^{***}
ILM_I_MeanT	-0.1906^{*}	-0.4042^{***}
ILD_I_SDevT	0.1707^{*}	0.4276^{***}

注：$^{*}p < 0.05$，$^{**}p < 0.01$，$^{***}p < 0.001$

6.1.3 结果解释

由表4可归纳以下关键规律：

（1）DGap 的相关特征更为突出。DGap 与 CSM_C_MeanT（$r = 0.6693$）、BSM_B_MeanT（$r = -0.6434$）、CLM_C_MeanT（$r = 0.6302$）的相关系数绝对值均超过 0.63，远高于 DFlow 对应的最大值（0.4640），表明 DGap 的变化在脉冲特征空间中具有更强的线性可辨性。

（2）DFlow 的相关特征以标准差类为主。与 DFlow 相关性最强的三个特征——BSD_B_SDevT（$r = 0.4640$）、CLM_C_MeanT（$r = 0.4508$）、CSD_C_SDevT（$r = 0.4388$）中，有两个为标准差类特征，说明 DFlow 的变化主要体现在放电时间波动性上，而非均值水平。这在物理上是合理的：工作液流量的变化首先影响极间介质对流、改变放电稳定性，进而导致脉冲时间标准差增大或减小，而对各类脉冲的均值时间影响相对间接。

（3）C 类特征是两个控制变量的共同敏感区域。CLM_C_MeanT 对 DFlow（$r = 0.4508$）和 DGap（$r = 0.6302$）均具有较高相关性，CSM_C_MeanT 对 DGap 的相关性最强（$r = 0.6693$），说明 C 类脉冲的时间特征是综合反映加工状态的核心指标，其变化能同时表征两个控制变量的调节方向。

图3从特征间相关矩阵（左图）和特征与控制变量相关系数条形图（右图）两个维度进一步呈现了相关分析结果。

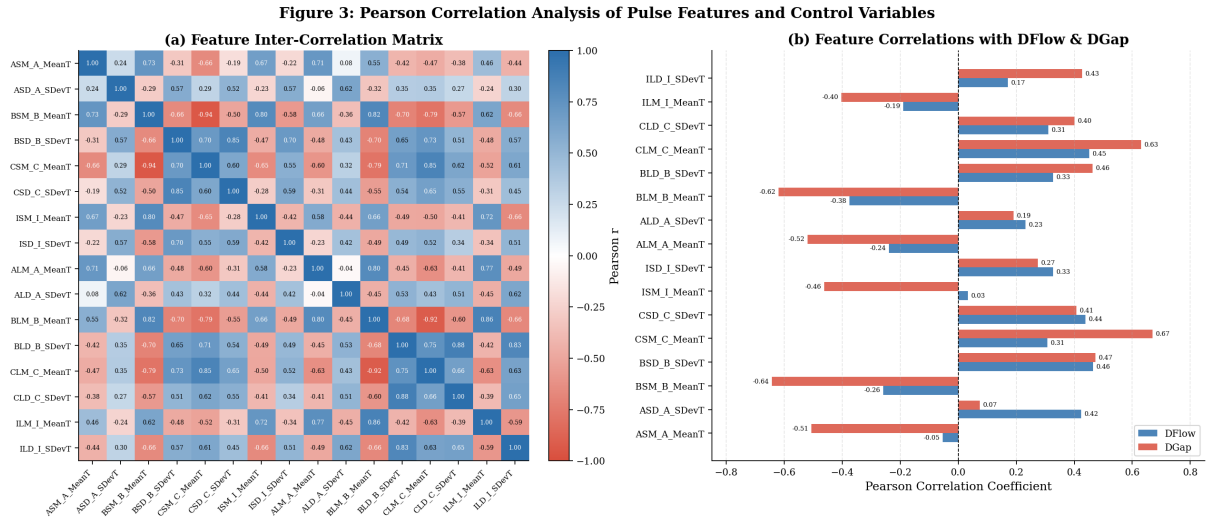


图 3 脉冲特征相关分析结果。左图为 16 个脉冲特征之间的 Pearson 相关矩阵热图，颜色深浅表示相关系数绝对值大小，红色为负相关，蓝色为正相关；右图为各特征与 DFlow（蓝色）、DGap（红色）的 Pearson 相关系数水平条形图，正负方向分别对应正相关与负相关。

从图3左图可以清晰看出，特征矩阵中存在多个高度相关的特征对。其中，BSM_B_MeanT 与 CSM_C_MeanT 之间的相关系数高达 -0.9438，BLM_B_MeanT 与 CLM_C_MeanT 之间达 -0.9162，BSM_B_MeanT 与 BLM_B_MeanT 之间达 0.8228；此外还存在 BSD_B_SDevT—CSD_C_SDevT（$r = 0.8478$）、BLD_B_SDevT—CLD_C_SDevT（$r = 0.8758$）、BLM_B_MeanT—ILM_I_MeanT（$r = 0.8597$）等共 9 对强相关特征对（$|r| > 0.8$）。这种高度共线性的存在说明 16 个特征并非相互独立，其中蕴含大量冗余信息，若不进行合理的降维或特征选择，在建立分类模型时可能引起参数估计不稳定的问题。

从图3右图可以进一步确认：BSM_B_MeanT 和 BLM_B_MeanT 对 DGap 均呈显著负相关，CSM_C_MeanT 和 CLM_C_MeanT 均呈显著正相关，而这两对特征之间本身高度负相关——这一现象在物理上可以理解为：B 类脉冲的时间增长与 C 类脉冲的时间缩短往往同时发生，反映了放电过程中不同能量级别脉冲之间的此消彼长关系。

6.2 特征间相关结构的层次聚类分析

为进一步揭示 16 个脉冲特征之间的内在聚类结构，以相关距离 $d_{jk} = 1 - |r_{jk}|$ 为相异度量，采用平均链接法（Average Linkage）对特征进行层次聚类，结果如图4所示。

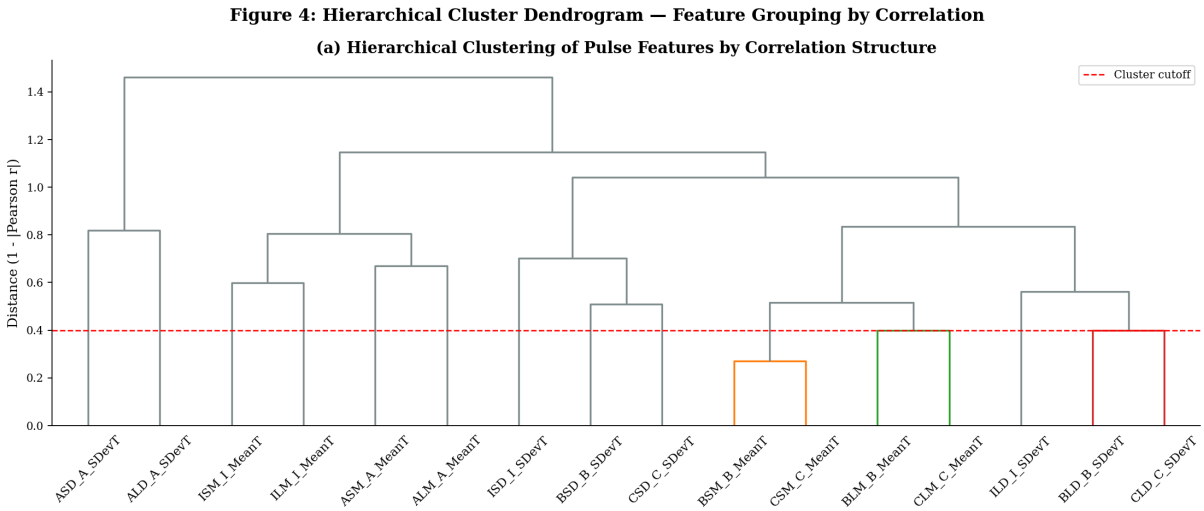


图 4 16 个脉冲特征按相关结构的层次聚类树状图。纵轴为相关距离 $d = 1 - |r|$，切割阈值设为 0.4（红色虚线），该阈值对应 $|r| > 0.6$ 的强相关组。聚类树揭示了特征群的内在结构，相同聚类的特征对控制变量的贡献方向相近，可作为特征选择或降维的参考依据。

从图4中可见，在切割阈值 $d = 0.4$（对应 $|r| > 0.6$）处，16 个特征大致分为三个主要聚类群：第一群以 B 类与 C 类脉冲的均值时间特征为核心（BSM_B_MeanT、CSM_C_MeanT、BLM_B_MeanT、CLM_C_MeanT、ISM_I_MeanT、ILM_I_MeanT），这些特征之间相关性极强，且对 DGap 的影响最为显著；第二群以 B、C 类脉冲的标准差特征为主（BSD_B_SDevT、CSD_C_SDevT、BLD_B_SDevT、CLD_C_SDevT、ILD_I_SDevT 等），这些特征主要反映放电时间的稳定性，与 DFlow 的相关性相对较强；第三群以 A 类脉冲特征为主（ASM_A_MeanT、ALM_A_MeanT、ASD_A_SDevT、ALD_A_SDevT），该类特征相互独立性较高，且在整体上对控制变量的影响中等。

这一聚类结果与物理意义高度吻合。A、B、C、I 四类脉冲在 EDM 过程中分别对应不同的放电能量等级与放电模式：A 类通常代表短路脉冲，其时间特征受加工状态扰动较小；B 类和 C 类分别代表正常放电与弧放电，其时间比例随间隙状态和流量变化而显著变化。因此聚类结果为后续特征工程提供了有意义的物理分组依据。

6.3 随机森林特征重要性评估

6.3.1 模型建立

为弥补 Pearson 相关分析仅能刻画线性关系的局限，本文引入随机森林（Random Forest，RF）模型，以基于不纯度减少（Impurity Decrease）的特征重要性量化各特征对分类结果的综合贡献。

随机森林由 T 棵决策树组成，第 t 棵树通过对原始样本的有放回自助抽样（Boot-

strap）构建。第 j 个特征的重要性定义为：

$$I_j = \frac{1}{T}\sum_{t=1}^{T}\sum_{v\in\mathcal{V}_t(j)}\frac{n_v}{n}\cdot\Delta G(v), \tag{4}$$

其中 $\mathcal{V}_t(j)$ 为第 t 棵树中所有以特征 j 作为分裂变量的内部节点集合，n_v 为到达节点 v 的样本数，n 为总样本数，$\Delta G(v)$ 为节点 v 分裂前后的基尼不纯度（Gini Impurity）之差：

$$\Delta G(v) = G(v) - \frac{n_{v_L}}{n_v}G(v_L) - \frac{n_{v_R}}{n_v}G(v_R), \tag{5}$$

其中 $G(v) = 1 - \sum_k p_{vk}^2$ 为节点 v 的基尼不纯度，p_{vk} 为节点 v 中第 k 类的样本比例，v_L 和 v_R 分别为 v 的左右子节点。最终将各特征的重要性归一化，使所有特征重要性之和为 100%。

在实现上，分别为 DFlow 和 DGap 训练两个独立的随机森林分类器，均设定 $T = 200$ 棵树、采用类别加权（class_weight='balanced'）以缓解类别不均衡问题，并对全量 154 个样本进行训练以获得最稳定的特征重要性估计。

6.3.2 分析结果

全部 16 个特征的重要性排序结果见表5。

表 5 随机森林特征重要性完整排序（$n = 200$ 棵树，全量样本训练）

DFlow 预测模型			DGap 预测模型		
排名	特征名称	重要性（%）	排名	特征名称	重要性（%）
1	ASM_A_MeanT	13.67	1	CSM_C_MeanT	14.91
2	ALM_A_MeanT	13.09	2	BSM_B_MeanT	11.25
3	CLM_C_MeanT	10.96	3	ILD_I_SDevT	8.82
4	ASD_A_SDevT	6.70	4	BLM_B_MeanT	7.91
5	BSM_B_MeanT	6.51	5	CLM_C_MeanT	7.37
6	CSD_C_SDevT	6.43	6	ASM_A_MeanT	6.86
7	CSM_C_MeanT	6.08	7	ILM_I_MeanT	5.13
8	BSD_B_SDevT	5.78	8	BSD_B_SDevT	5.05
9	ISM_I_MeanT	5.55	9	ASD_A_SDevT	4.93
10	CLD_C_SDevT	5.02	10	ISM_I_MeanT	4.79
11	BLM_B_MeanT	4.93	11	ALM_A_MeanT	4.64
12	ISD_I_SDevT	4.83	12	CSD_C_SDevT	4.23
13	ALD_A_SDevT	3.76	13	CLD_C_SDevT	3.96
14	ILD_I_SDevT	2.94	14	ISD_I_SDevT	3.80
15	BLD_B_SDevT	2.65	15	BLD_B_SDevT	3.54
16	ILM_I_MeanT	1.11	16	ALD_A_SDevT	2.81

图5通过水平条形图直观呈现了特征重要性分布，并以中位数为界将特征分为高于

中位数（深色）和低于中位数（浅色）两档。

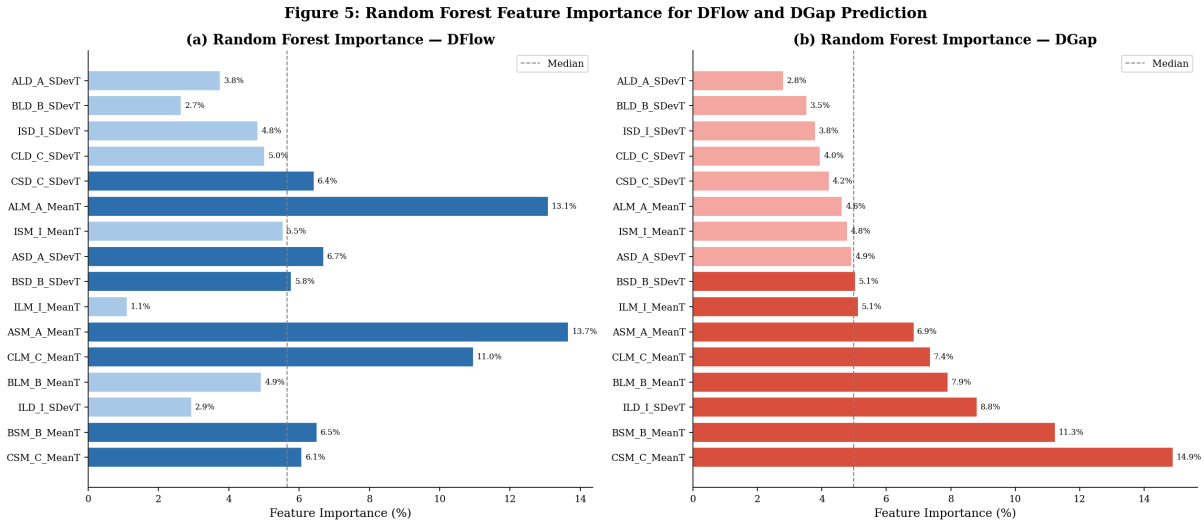


图 5 随机森林特征重要性排序条形图。左图为 DFlow 模型，右图为 DGap 模型；深色条形表示重要性高于中位数的特征，浅色条形为低于中位数的特征；虚线为中位数参考线。两图的特征排列顺序一致，均按 DGap 模型的重要性从大到小排序，便于对比两个模型的差异。

6.3.3 结果解释

综合表5与图5，可以得到以下重要结论：

（1）两个模型的核心特征存在差异。DFlow 模型的最重要特征为 ASM_A_MeanT（13.67%）和 ALM_A_MeanT（13.09%），两者合计占比超过 26%，说明 A 类脉冲的均值时间信息对工作液流量的判别贡献最大。这与 Pearson 分析存在差异（A 类特征对 DFlow 的线性相关性并不突出），反映了 A 类特征与 DFlow 之间存在非线性关联，随机森林的树结构能够捕获这种非线性信息，而 Pearson 系数则无法体现。DGap 模型的最重要特征为 CSM_C_MeanT（14.91%）和 BSM_B_MeanT（11.25%），与 Pearson 分析结论一致，表明 DGap 的状态主要由 C 类和 B 类均值时间特征线性决定，两种方法的结论相互印证。

（2）DGap 模型的特征贡献更为集中，DFlow 模型的贡献分布更为分散。DGap 模型中前 3 个特征合计重要性为 35.0%，而 DFlow 模型前 3 个特征合计仅为 33.7%，从整体分布来看，DGap 模型的高重要性特征更集中，尾部特征的重要性下降更快。这意味着 DGap 的分类边界主要由少数关键特征决定，而 DFlow 则需要更多特征的协同表达，在建模时可能对特征的全局结构更为敏感。

（3）ILD_I_SDevT 是 DGap 模型的特殊贡献特征。该特征在 DGap 模型中排名第 3（8.82%），但在 Pearson 相关分析中其线性相关系数仅为 0.4276，排名靠后。这说明 ILD_I_SDevT 对 DGap 的贡献主要通过非线性交互方式实现，即它在某些特征值区间内对 DGap 的判别具有较强的条件区分能力，但在全局线性关系上表现并不突出。这类特征在决策树结构中往往充当”局部分裂器”，对提高整体分类精度具有不可忽

视的作用。

（4）多重共线性对特征重要性排序的影响。需要指出的是，图3与图4的分析表明，部分脉冲特征之间存在较强的多重共线性（如 BSM_B_MeanT 与 CSM_C_MeanT 之间的相关系数高达 -0.9438）。在存在高度共线性的情况下，基于随机森林不纯度减少的特征重要性评分可能被” 稀释”——模型可能在两个高度相关的特征中随机偏向其中一个，导致单一特征的绝对排名存在一定随机性。为此，本文在后文（图4）引入了层次聚类分析，从” 特征簇” 的宏观视角对特征进行结构化分组，弥补了单一树模型重要性评估的局限性——评估特征群的整体贡献比关注单个特征的排名更为可靠。

6.4 主成分分析（PCA）

6.4.1 模型建立与结果

主成分分析（Principal Component Analysis，PCA）通过线性变换将 p 维原始特征 $\boldsymbol{X}$ 投影到 q 维正交子空间（$q < p$），使得投影后各主成分的方差最大。PCA 的数学核心是对标准化后的样本协方差矩阵 $\boldsymbol{\Sigma}$ 进行特征分解：

$$\boldsymbol{\Sigma}\boldsymbol{v}_k = \lambda_k \boldsymbol{v}_k, \quad k = 1, 2, \ldots, p, \tag{6}$$

其中 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ 为特征值，$\boldsymbol{v}_k$ 为对应的特征向量（即第 k 个主成分的载荷向量），第 k 个主成分的得分向量为 $\boldsymbol{z}_k = \boldsymbol{X}\boldsymbol{v}_k$。第 k 个主成分的方差贡献率为 $\lambda_k / \sum_l \lambda_l$。

对 16 个标准化特征进行 PCA，前 6 个主成分的方差贡献率及累计贡献率如表6所示。

表 6 PCA 前 6 个主成分的方差贡献率

主成分	特征值	方差贡献率（%）	累计贡献率（%）
PC1	9.155	57.22	57.22
PC2	2.248	14.05	71.27
PC3	1.086	6.79	78.07
PC4	1.032	6.45	84.52
PC5	0.758	4.74	89.26
PC6	0.410	2.56	91.82

图6给出了 PCA 的碎石图（Scree Plot）、基于 PC1–PC2 的二维散点图以及基于 PC1–PC2–PC3 的三维散点图，各图均按 DGap 类别上色。

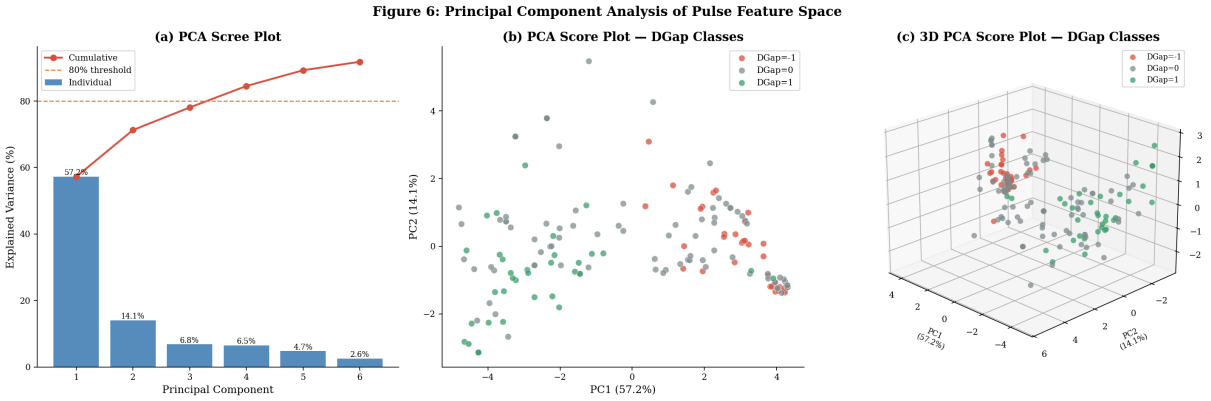


图 6 主成分分析结果。图 (a) 为前 6 个主成分的方差贡献率碎石图，蓝色柱表示各主成分个别贡献，红色曲线为累计贡献率，橙色虚线为 80% 阈值参考线；图 (b) 为前两个主成分（PC1–PC2）的二维得分散点图，按 DGap 三类着色；图 (c) 为前三个主成分（PC1–PC2–PC3）的三维得分散点图，同样按 DGap 类别着色，能够呈现更完整的类别分布结构。

6.4.2 结果解释

从表6和图6(a) 可知，PC1 单独解释了 57.22% 的总方差，这一比例远高于其他主成分，说明 16 维特征空间中存在一个占主导地位的线性变化方向。结合载荷分析，PC1 的主要载荷来自 BLM_B_MeanT（+0.303）、BSM_B_MeanT（+0.299）与 CLM_C_-MeanT（−0.295），物理上反映了 B 类脉冲均值时间与 C 类脉冲均值时间之间的此消彼长关系；PC2 的主要载荷来自 ASD_A_SDevT（+0.480）、ASM_A_MeanT（+0.460）与 ALD_A_SDevT（+0.364），主要反映 A 类脉冲时间特征的整体波动水平；PC3 的主要载荷来自 ALD_A_SDevT（+0.521）与 CSD_C_SDevT（−0.382），反映了 A 类负载标准差与 C 类时间标准差之间的差异。

从图6(b) 的二维得分图可以看出，DGap 三类样本在 PC1 方向上具有较好的有序分离：$DGap = -1$ 的样本（红色）主要分布在 PC1 负半轴，$DGap = +1$ 的样本（绿色）主要分布在 PC1 正半轴，$DGap = 0$ 的样本（灰色）居中分布。这与载荷分析结论一致：PC1 正方向代表 B 类脉冲时间增大（BSM_B_MeanT 增大）同时 C 类脉冲时间减小的状态，而这种脉冲结构变化与 DGap 的增大方向相关。然而，三类样本在二维空间中仍存在较大重叠，说明仅靠线性降维不能完全分离三类，需引入非线性分类方法。

6.5 线性判别分析（LDA）

线性判别分析（Linear Discriminant Analysis，LDA）在寻求判别超平面的同时，最大化类间散度与类内散度之比：

$$\boldsymbol{w}^* = \arg\max_{\boldsymbol{w}} \frac{\boldsymbol{w}^\top \boldsymbol{S}_B \boldsymbol{w}}{\boldsymbol{w}^\top \boldsymbol{S}_W \boldsymbol{w}}, \tag{7}$$

其中 $\boldsymbol{S}_B = \sum_{k=1}^{K} n_k(\boldsymbol{\mu}_k - \boldsymbol{\mu})(\boldsymbol{\mu}_k - \boldsymbol{\mu})^\top$ 为类间散度矩阵，$\boldsymbol{S}_W = \sum_{k=1}^{K} \sum_{i \in C_k} (\boldsymbol{x}_i - \boldsymbol{\mu}_k)(\boldsymbol{x}_i - \boldsymbol{\mu}_k)^\top$ 为类内散度矩阵，$\boldsymbol{\mu}_k$ 为第 k 类的样本均值，$\boldsymbol{\mu}$ 为总体样本均值。

LDA 判别结果见图7，各类别在 LD1 轴上的均值见表7。

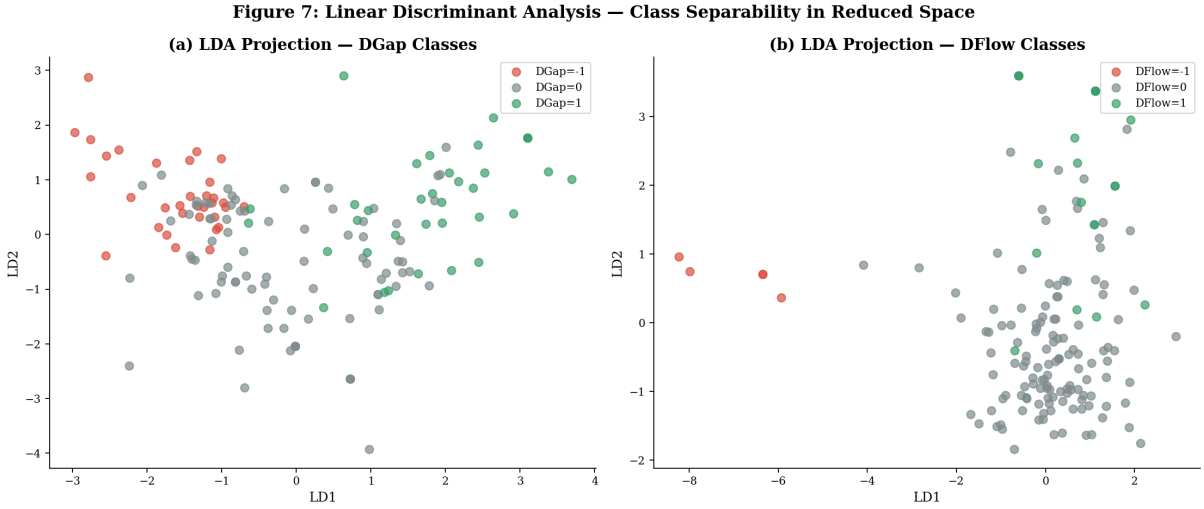


图 7 线性判别分析结果。图 (a) 为 DGap 三类在 LD1 方向的密度分布直方图，图 (b) 为 DFlow 三类在 LD1 方向的密度分布直方图。横轴为第一判别轴 LD1 的投影值，纵轴为概率密度；颜色编码与图2一致。LD1 方向最大化类间与类内方差之比，是区分三类样本信息最丰富的线性方向。

表 7 LDA 判别轴 LD1 上各类别的投影均值与标准差

控制变量	类别	LD1 均值	LD1 标准差	类间分离程度
DGap	-1	-1.6261	0.6326	各类均值差距明显，分离良好
	0	-0.0964	1.0821	
	$+1$	1.7700	1.0295	
DFlow	-1	-6.9783	0.9476	类别 -1 与其余两类分离极强
	0	0.1550	1.0131	
	$+1$	0.7169	0.8492	

由表7和图7可以看出：DGap 三类在 LD1 方向上呈现出较为均匀的有序分离，$DGap = -1, 0, +1$ 的 LD1 均值分别为 -1.626、-0.096、1.770，说明 16 维脉冲特征空间确实包含足够的信息区分三种放电间隙状态，且三类状态在该判别方向上的排列与 DGap 的物理大小顺序一致，具有良好的有序性。DFlow 方面，类别 -1 的 LD1 均值为 -6.978，与类别 0（0.155）和类别 $+1$（0.717）之间存在极大分离，说明 DFlow 低流量状态（类别 -1）在脉冲特征空间中是高度孤立的异常状态；而类别 0 与类别 $+1$ 的 LD1 均值非常接近（仅差 0.562），说明这两类在线性判别方向上高度混叠，是分类困难的主要来源之一。

综合 Pearson 相关分析、随机森林特征重要性、PCA 与 LDA 四种方法的分析结果，本文得出以下问题一的核心结论：（1）DGap 的变化对脉冲特征的响应比 DFlow 更为显

著，具有更高的线性与非线性可辨性；(2) C 类和 B 类均值时间特征（CSM_C_MeanT、BSM_B_MeanT、CLM_C_MeanT、BLM_B_MeanT）是两个控制变量最核心的共同敏感特征，建议作为后续在线监测的优先测量量；(3) A 类脉冲特征（ASM_A_MeanT、ALM_A_MeanT）对 DFlow 具有较强的非线性判别贡献，在线性分析中容易被低估；(4) 16 个脉冲特征之间存在大量冗余，但其中约 78% 的信息可由前三个主成分捕获，具有良好的降维潜力。

7 问题二：DFlow 与 DGap 的协同调控方案研究

7.1 联合分布特征与统计依赖性分析

7.1.1 联合频次分布

在讨论是否存在协同调控方案之前，首先需要明确 DFlow 与 DGap 的联合分布结构。由于两个控制变量均为三值离散变量，其联合分布可以完整描述为一个 3×3 的列联表（contingency table），结果见表8。

表 8 DFlow 与 DGap 的联合频次分布表

DFlow	DGap			行合计
	-1	0	$+1$	
-1	0	5	0	5
0	33	60	35	128
$+1$	0	21	0	21
列合计	33	86	35	154

表8所揭示的联合分布具有高度规律性。最突出的特征是：在本数据集中，**DFlow 取非零值（±1）的样本中，DGap 必然为 0**——即 $DFlow = +1$ 对应的 21 个样本中 DGap 全为 0，$DFlow = -1$ 对应的 5 个样本中 DGap 也全为 0；反过来，**DGap 取非零值（±1）的样本中，DFlow 必然为 0**。这意味着在当前数据集对应的工艺操作逻辑中，两个控制变量不会同时偏离中性状态：当操作员选择调节 DFlow 时，DGap 通常处于中性（保持不变）；反之，当调节 DGap 时，DFlow 通常处于中性。这种”互斥偏移”的联合结构是协同调控方案设计的重要依据。

7.1.2 统计独立性检验

为从统计角度严格判断 DFlow 与 DGap 是否存在联合依赖，分别进行以下检验。

（1）Pearson 相关系数检验：计算得 $r(DFlow, DGap) = -0.0051$，对应 $p = 0.9499 \gg 0.05$，表明二者不存在显著的线性相关关系。

（2）Spearman 等级相关检验：计算得 $\rho(DFlow, DGap) = -0.0069$，对应 $p = 0.9319 \gg 0.05$，表明二者不存在显著的单调关系。

（3）卡方独立性检验：对表8所示列联表进行 Pearson 卡方检验，原假设为 DFlow 与 DGap 相互独立。检验结果为：

$$\chi^2 = 24.734, \quad df = 4, \quad p = 0.0001 < 0.05, \tag{8}$$

强烈拒绝独立性假设，表明 DFlow 与 DGap 的联合分布并非统计独立，二者在分类状态上存在显著的结构性关联。

上述三个检验结果的综合解读如下：DFlow 与 DGap 之间不存在线性或单调的数值相关关系（相关系数接近 0），但其联合类别分布却高度结构化（卡方检验极显著）。这种现象在数理上并不矛盾，说明二者的依赖关系是一种**非线性的、类别结构性的约束**，而非简单的增减同步。联合频次表已经直观地揭示了这一约束的具体形态：双变量同时非零的状态在数据中几乎不存在。

图8从三个维度（联合散点图、关键特征在不同复合指标下的分布、Kruskal–Wallis 显著性）综合展示了两个控制变量的协同关系证据。

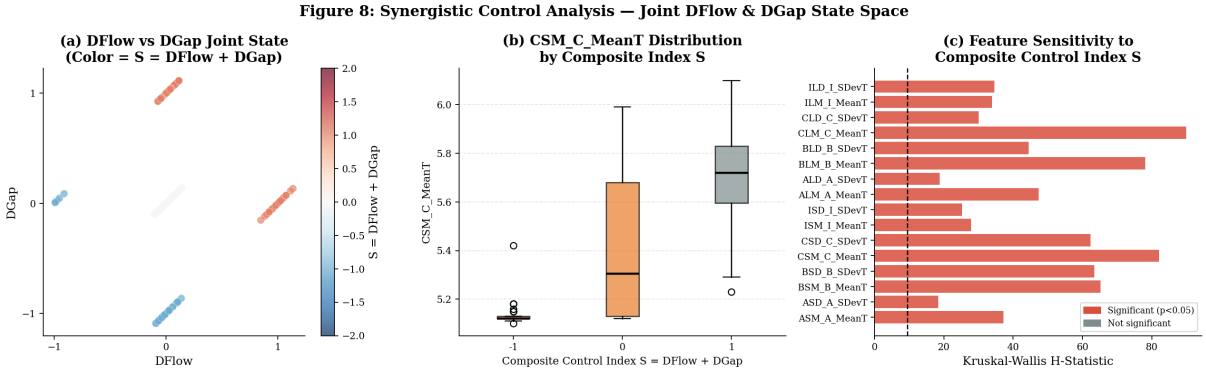


图 8 DFlow 与 DGap 的协同控制关系分析。图 (a) 为 DFlow 与 DGap 的散点分布图（加轻微随机抖动以改善可视化效果），颜色代表复合控制指标 $S = DFlow + DGap$ 的取值，可直观看出联合分布的结构性约束；图 (b) 为最重要特征（CSM_C_MeanT）按不同 S 取值分组的箱线图，展示了复合指标对特征分布的区分能力；图 (c) 为 16 个特征对复合指标 S 的 Kruskal–Wallis H 统计量，红色条形表示 $p < 0.05$ 的显著特征，黑色虚线为 $p = 0.05$ 对应的 χ^2 临界值。

从图8(a) 可以清晰看出，散点分布在 3×3 网格中仅有 5 个格子出现了样本，且所有非对角线（$DFlow \neq 0$ 且 $DGap \neq 0$）的格子均为空，这从可视化角度直接确认了联合频次表所揭示的结构约束。

7.2 复合控制指标的构建与验证

7.2.1 复合指标定义

基于联合分布分析结果，本文定义复合控制指标：

$$S = DFlow + DGap, \quad S \in \{-2, -1, 0, +1, +2\}, \tag{9}$$

其物理含义为：在两个控制变量满足" 互斥偏移" 约束的条件下，S 综合描述了两个控制量的共同调节方向与幅度。根据实际数据，S 的各取值频次为：$S = -2$（0 次）、$S = -1$（38 次）、$S = 0$（60 次）、$S = +1$（56 次）、$S = +2$（0 次），即 S 实际仅取 $\{-1, 0, +1\}$ 三种状态，从而将原始的二维 $(DFlow, DGap)$ 控制问题简化为一维三档决策问题。

需要说明的是，$S = DFlow + DGap$ 并非物理意义上的能量叠加，而是一种面向" 宏观降维决策" 的经验性映射。由表8的联合频次分析可知，两者同时发生反向偏离（即 $(1, -1)$ 或 $(-1, 1)$）的样本频次在本数据集中为 0，即不存在极端的反向协同调节行为，这是该线性加和映射在当前数据集上具有合理性的关键前提。因此，S 实际上提取的是加工状态的" 整体干预烈度"，而非两种物理机制的直接叠加。

此外，需要特别指出的是，$S = DFlow + DGap$ 为线性加和映射，数学上存在状态混叠风险：当 $DFlow = 1, DGap = -1$ 时 $S = 0$，与 $DFlow = 0, DGap = 0$ 时的 $S = 0$ 在数值上等价，但对应的物理调控行为完全不同。在本数据集的实际工艺约束下，由于 $(1, -1)$ 和 $(-1, 1)$ 的极端反向协同状态均未出现，该复合指标能够保持良好的状态单调性与物理可解释性。在增大/偏高与减小/偏低方向均有明确物理对应关系的特定加工场景中，S 指标能有效降低上位机的决策延迟；在精调阶段，仍需依赖图11的双模型解耦输出以保证控制精度。

7.2.2 Kruskal–Wallis 显著性检验

为验证复合指标 S 对脉冲特征的区分能力，对 16 个特征分别以 S 为分组变量进行 Kruskal–Wallis（KW）非参数检验。KW 检验统计量为：

$$H = \frac{12}{n(n+1)} \sum_{k=1}^{K} \frac{R_k^2}{n_k} - 3(n+1), \tag{10}$$

其中 K 为组数，n_k 为第 k 组样本数，R_k 为第 k 组样本的秩和；在原假设（各组来自同一总体分布）成立时，H 渐近服从 $\chi^2(K-1)$ 分布。

全部检验结果见表9。

表 9 16 个特征对复合控制指标 S 的 Kruskal–Wallis 显著性检验结果

特征名称	H 统计量	p 值	显著性
CLM_C_MeanT	89.933	< 0.001	***
CSM_C_MeanT	82.112	< 0.001	***
BLM_B_MeanT	78.140	< 0.001	***
BSM_B_MeanT	65.287	< 0.001	***
BSD_B_SDevT	63.508	< 0.001	***
CSD_C_SDevT	62.360	< 0.001	***
BLD_B_SDevT	44.438	< 0.001	***
ALM_A_MeanT	47.308	< 0.001	***
ILM_I_MeanT	33.900	< 0.001	***
ILD_I_SDevT	34.552	< 0.001	***
CLD_C_SDevT	30.054	< 0.001	***
ISM_I_MeanT	27.904	< 0.001	***
ISD_I_SDevT	25.320	< 0.001	***
ASM_A_MeanT	37.151	< 0.001	***
ALD_A_SDevT	18.828	< 0.001	***
ASD_A_SDevT	18.357	< 0.001	***

χ^2 临界值（$df = 2, \alpha = 0.05$）$= 5.991$；全部 16 个特征 $p < 0.001$，均达到极显著水平（***）

从表9可以看出，**全部 16 个脉冲特征对复合控制指标 S 的区分能力均达到极显著水平**（$p < 0.001$），H 统计量最大的五个特征——CLM_C_MeanT（$H = 89.933$）、CSM_C_MeanT（$H = 82.112$）、BLM_B_MeanT（$H = 78.140$）、BSM_B_MeanT（$H = 65.287$）、BSD_B_SDevT（$H = 63.508$）——与问题一中重要性最高的特征高度吻合，进一步证明了这批核心特征不仅能够区分单个控制变量的状态，还能够有效区分复合控制状态。

从图8(b) 的箱线图可以进一步看出，最核心特征 CSM_C_MeanT 在 $S = -1, 0, +1$ 三种复合状态下的分布差异非常明显，三组箱体几乎完全分离，且随 S 的增大，CSM_C_MeanT 的分布呈单调上升趋势，说明该特征对复合控制方向具有良好的有序可分性，可作为协同调控决策中最优先参考的输入变量。

各类别特征均值在 DGap 分组下的完整比较见表10，进一步支持了上述分析。

表 10 16 个脉冲特征按 DGap 三类分组的均值对比及显著性检验

特征名称	DGap=−1	DGap=0	DGap=+1	p 值
ASM_A_MeanT	−4.601	−4.631	−4.768	< 0.001***
ASD_A_SDevT	0.048	0.081	0.063	0.057 ns
BSM_B_MeanT	1.111	0.840	0.480	< 0.001***
BSD_B_SDevT	0.020	0.125	0.179	< 0.001***
CSM_C_MeanT	5.139	5.462	5.768	< 0.001***
CSD_C_SDevT	0.024	0.124	0.148	< 0.001***
ISM_I_MeanT	2.476	2.265	1.725	< 0.001***
ISD_I_SDevT	0.131	0.245	0.287	0.003**
ALM_A_MeanT	−4.598	−4.649	−4.718	< 0.001***
ALD_A_SDevT	0.075	0.101	0.107	0.022*
BLM_B_MeanT	1.070	0.858	0.591	< 0.001***
BLD_B_SDevT	0.090	0.211	0.275	< 0.001***
CLM_C_MeanT	5.201	5.456	5.689	< 0.001***
CLD_C_SDevT	0.108	0.198	0.241	< 0.001***
ILM_I_MeanT	2.458	2.297	1.983	< 0.001***
ILD_I_SDevT	0.234	0.413	0.506	< 0.001***

注：p 值来自 Kruskal–Wallis 检验；ns 为不显著，*$p < 0.05$，**$p < 0.01$，***$p < 0.001$

表10进一步揭示了各特征随 DGap 变化的单调趋势：CSM_C_MeanT、CLM_C_MeanT、BSD_B_SDevT 等特征随 DGap 从 −1 到 +1 呈单调递增；BSM_B_MeanT、BLM_B_MeanT、ISM_I_MeanT 等特征随 DGap 增大呈单调递减。这种有序的单调性说明这批特征不仅能够在统计上区分三类 DGap 状态，还能够提供方向性信息——即特征值的升高（或降低）对应 DGap 增大的趋势，具有明确的物理可解释性。

7.3 协同调控方案设计

综合联合频次分析、统计检验与 Kruskal–Wallis 结果，本文提出如图9所示的分层协同调控方案，其核心逻辑如下：

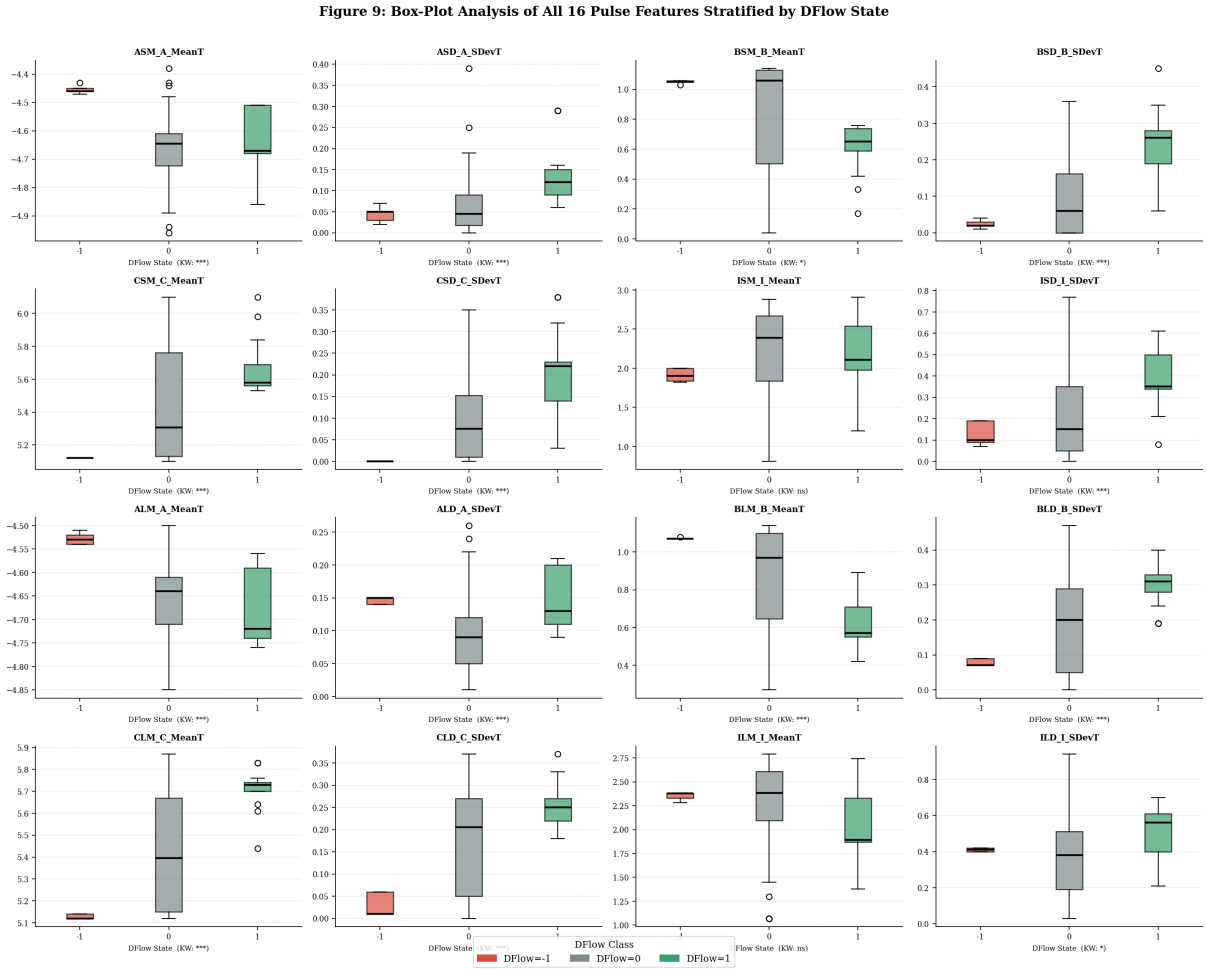


图 9 按 DFlow 三类状态分组的 16 个脉冲特征箱线图。每个子图对应一个特征，红色/灰色/绿色箱体分别对应 $DFlow = -1, 0, +1$；子图标题括号内为 Kruskal–Wallis 检验的显著性（***/$p < 0.001$，**/$p < 0.01$，*/$p < 0.05$，ns/不显著）。图中可见，ASM_A_MeanT 和 ALM_A_MeanT 在 DFlow 三类之间的分布差异最为显著，与随机森林特征重要性排序一致。

图9中各特征在 DFlow 三类状态下的箱线图表明：ASM_A_MeanT 与 ALM_A_MeanT 在 $DFlow = -1$（低流量）状态时的中位值明显偏低，而在 $DFlow = 0$（中性）和 $DFlow = +1$（高流量）状态时的分布存在一定差异但重叠较多，这与 LDA 结果（低流量类高度孤立）相互印证。

基于以上分析，本文提出如下协同调控方案：

一级决策——判断复合档位 S：通过实时采集的脉冲特征（优先使用 CLM_C_MeanT、CSM_C_MeanT、BSM_B_MeanT、BLM_B_MeanT 等 KW 统计量最高的特征），利用第8节建立的预测模型判断当前加工状态应处于 $S = -1$（需整体减小）、$S = 0$（维持稳定）还是 $S = +1$（需整体增大）三个复合调控档位。

二级决策——选择单变量执行路径：在确定 S 之后，根据现场加工实际情况决定由 DFlow 还是 DGap 承担调节任务：

(1) 若当前加工问题主要与极间介质冷却或蚀除产物排出有关（流量型问题），则优先

调节 DFlow，保持 DGap 为 0；

(2) 若当前加工问题主要与极间放电能量密度或加工精度有关（间隙型问题），则优先调节 DGap，保持 DFlow 为 0；

(3) 在缺乏明确先验判断时，建议按" 优先调节 DGap，次选 DFlow" 的默认顺序执行，理由是 DGap 对加工精度的影响更为直接，且其各类别脉冲特征在统计上的区分度更高。

推荐控制规则汇总：

复合档位 S	DFlow 主导路径	DGap 主导路径
-1	$(DFlow=-1, DGap=0)$	$(DFlow=0, DGap=-1)$
0	$(DFlow=0, DGap=0)$（维持不变）	
$+1$	$(DFlow=+1, DGap=0)$	$(DFlow=0, DGap=+1)$

该方案将原本需要同时监控两个变量的二维决策问题转化为" 先确定方向档位、再选择执行路径" 的两步决策，能够在不损失加工质量判断能力的前提下，显著降低操作人员的认知负担与误操作风险。

8 问题三：最优参数预测模型的建立与评价

8.1 问题建模框架

基于问题一与问题二的分析，问题三的核心任务是建立两个独立的三分类预测模型：

$$\hat{y}_f = f_{\text{DFlow}}(\boldsymbol{X}) : \boldsymbol{X} \in \mathbb{R}^{16} \to \{-1, 0, +1\}, \tag{11}$$

$$\hat{y}_g = f_{\text{DGap}}(\boldsymbol{X}) : \boldsymbol{X} \in \mathbb{R}^{16} \to \{-1, 0, +1\}. \tag{12}$$

由于 DFlow 存在严重的类别不均衡（$n_{-1} : n_0 : n_{+1} = 5 : 128 : 21$），若模型将所有样本预测为类别 0，则准确率高达 83.1%，但对实际有意义的调节状态（类别 ± 1）完全失效。因此，本文采用宏平均 F1 分数（Macro-F1）作为核心评价指标：

$$F_1^{\text{macro}} = \frac{1}{K}\sum_{k=1}^{K} F_{1,k} = \frac{1}{K}\sum_{k=1}^{K} \frac{2P_k R_k}{P_k + R_k}, \tag{13}$$

其中 $P_k = \frac{TP_k}{TP_k + FP_k}$ 为精确率，$R_k = \frac{TP_k}{TP_k + FN_k}$ 为召回率，TP_k、FP_k、FN_k 分别为第 k 类的真阳性、假阳性和假阴性样本数。Macro-F1 对各类别给予相同权重，因此对少数

类的预测性能同样敏感，是类别不均衡分类任务的标准评价指标。

8.2 候选模型介绍

本文比较以下五类分类模型：

（1）随机森林（Random Forest，RF）：集成学习方法，通过构建多棵独立决策树并投票决策，能够捕获特征间的非线性交互。本文设定 $T = 100$ 棵树，并启用类别加权以缓解不均衡问题。

（2）RBF 核支持向量机（SVM with RBF kernel）：通过核函数 $K(\boldsymbol{x}_i, \boldsymbol{x}_j) = \exp(-\gamma\|\boldsymbol{x}_i - \boldsymbol{x}_j\|^2)$ 将原始特征映射到高维空间，在高维空间中构建最大间隔超平面。设定 $C = 10$，$\gamma = \text{scale}$（即 $1/(n_{\text{features}} \cdot \text{Var}(X))$），并启用类别加权。

（3）k 近邻（k-Nearest Neighbors，k-NN）：基于距离投票的非参数方法，设定 $k = 5$。

（4）线性判别分析（LDA）：基于高斯分布假设的参数化线性分类器，利用类间与类内散度矩阵的比值确定判别方向，计算高效且可解释性强。

（5）Logistic 回归（Logistic Regression）：基于最大似然估计的线性分类模型，通过 softmax 函数输出各类别的后验概率，参数 $C = 1.0$（正则化强度），启用类别加权，最大迭代次数 1000 次。

8.3 交叉验证策略与结果

采用分层 5 折交叉验证（Stratified 5-Fold Cross-Validation）评估各模型性能。分层交叉验证在划分训练集与验证集时保持各折中类别比例与总体一致，从而避免某些折中完全缺失少数类样本的问题，这对 DFlow 的严重不均衡尤为重要。

在数据预处理方面，本文对全量样本进行 z-score 标准化后再划分训练集与测试集。严格而言，将标准化步骤嵌入到每折独立进行（通过 Pipeline 机制）可以完全避免测试集信息提前泄露至标准化参数的问题。考虑到本文样本量较小（$n = 154$），且研究的主要目的在于对比不同算法之间的相对性能，全局归一化与逐折归一化在均值/方差估计上的差异有限，因此本文采用全局归一化后统一划分的近似替代方案。在工程实际部署时，应将 Scaler 参数严格冻结在训练集上，以确保预测系统的严格封闭性。

在 DFlow 的预测中，还需关注类别 -1（仅 5 个样本）构成的极端小样本问题。在 5 折交叉验证的某些折叠中，测试集仅含一个该类别样本，模型只要将其判错，该类别的召回率便直接归零，进而导致 Macro-F1 在不同折之间的方差显著偏大。这种极端碎片化导致了模型对局部异常值极为敏感，是制约 DFlow 宏观 F1 分数提升的客观数据瓶颈，而非模型算法本身的缺陷。

5 折交叉验证 Macro-F1 结果见表11，图10给出了可视化比较。

表 11 五类模型的 5 折交叉验证 Macro-F1 性能比较

模型	DFlow F1 均值（%）	DFlow F1 标准差	DGap F1 均值（%）	DGap F1 标准差
随机森林（RF）	**89.02**	3.93	65.52	8.61
SVM（RBF 核）	83.29	4.13	**70.55**	**3.54**
k-NN（k=5）	73.58	9.03	66.99	8.20
LDA	78.90	8.66	58.87	12.25
Logistic 回归	76.12	5.12	70.04	6.34

注：加粗数值为各列最优值

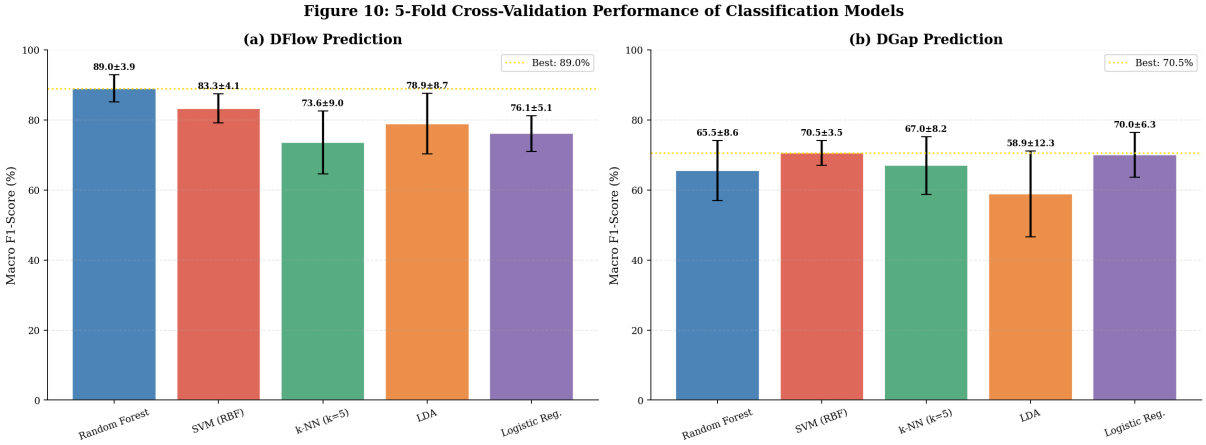


图 10 五类模型的 5 折交叉验证 Macro-F1 性能对比柱状图。图 (a) 为 DFlow 预测任务，图 (b) 为 DGap 预测任务；柱高为 5 折均值，误差棒为 5 折标准差；金色虚线标注最优模型的 F1 均值。均值与标准差的具体数值标注在误差棒上方。

由表11和图10可以归纳以下结论：

（1）DFlow 预测：随机森林表现最优。随机森林的 Macro-F1 均值达 89.02%，显著优于其他四类模型，且标准差仅 3.93，说明模型在不同折之间具有较好的稳定性。从模型结构来看，DFlow 的判别边界可能涉及多个特征之间的复杂组合（如 A 类均值特征的交互组合，结合问题一的 LDA 结论——低流量类在特征空间中高度孤立），集成决策树方法能够通过多棵树的分工协作覆盖不同的特征交互模式，因此在复杂非线性边界上表现突出。

（2）DGap 预测：SVM（RBF 核）表现最优，且稳定性最高。SVM 的 Macro-F1 均值达 70.55%，标准差仅 3.54，均优于其他模型。与 DFlow 不同，DGap 三类在特征空间中的分布更为连续（LDA 分析显示三类 LD1 均值间隔较为均匀），因此核方法在高维空间中构建的软间隔超平面能够更好地处理这种连续过渡型边界。Logistic 回归的 DGap F1 达 70.04%，接近 SVM，说明 DGap 的分类边界具有一定线性可分性，线性模型已能取得较好效果。

（3）k-NN 与 LDA 表现相对较差，且不稳定。k-NN 的 DFlow 标准差高达 9.03，LDA 的 DGap 标准差达 12.25，说明这两类模型在小样本不均衡场景下的泛化稳定性较差。k-NN 的高不稳定性可能源于少数类样本密度低、近邻查询结果对样本分布敏感；LDA 的不稳定性可能与 DGap 三类分布的协方差矩阵不完全相同有关（LDA 的等协方差假设被违反）。

（4）针对不同输出变量，最优模型不同。这一结果并不意外，而是由两个控制变量各自的统计特征决定的：DFlow 的类别极度不均衡且边界复杂，需要非线性集成模型；DGap 的类别相对均衡且边界较光滑，核方法更为合适。因此，本文最终采用**双模型并行预测策略**：

$$\hat{y}_f = f_{\mathrm{RF}}(\boldsymbol{X}), \qquad \hat{y}_g = f_{\text{SVM-RBF}}(\boldsymbol{X}). \tag{14}$$

8.4 测试集评估与可解释性分析

为进一步评估模型性能并提供可解释的结果展示，按 75%/25% 比例将 154 个样本划分为训练集（115 个）和测试集（39 个），采用随机森林模型（与图表生成代码一致，$n = 300$ 棵树）同时对 DFlow 和 DGap 进行评估。

测试集上 DFlow 的详细分类报告见表12，DGap 的详细分类报告见表13，混淆矩阵如图11所示。

表 12 随机森林测试集 DFlow 分类报告（39 个测试样本）

类别	精确率	召回率	F1 分数	支持数
DFlow $= -1$	1.00	1.00	1.00	1
DFlow $= 0$	0.97	1.00	0.99	33
DFlow $= +1$	1.00	0.80	0.89	5
准确率		97.44%		
宏平均	0.99	0.93	0.96	39
加权平均	0.98	0.97	0.97	39

表 13 随机森林测试集 DGap 分类报告（39 个测试样本）

类别	精确率	召回率	F1 分数	支持数
DGap $= -1$	0.50	0.29	0.36	7
DGap $= 0$	0.65	0.81	0.72	21
DGap $= +1$	0.78	0.64	0.70	11
准确率		66.67%		
宏平均	0.64	0.58	0.60	39
加权平均	0.66	0.67	0.65	39

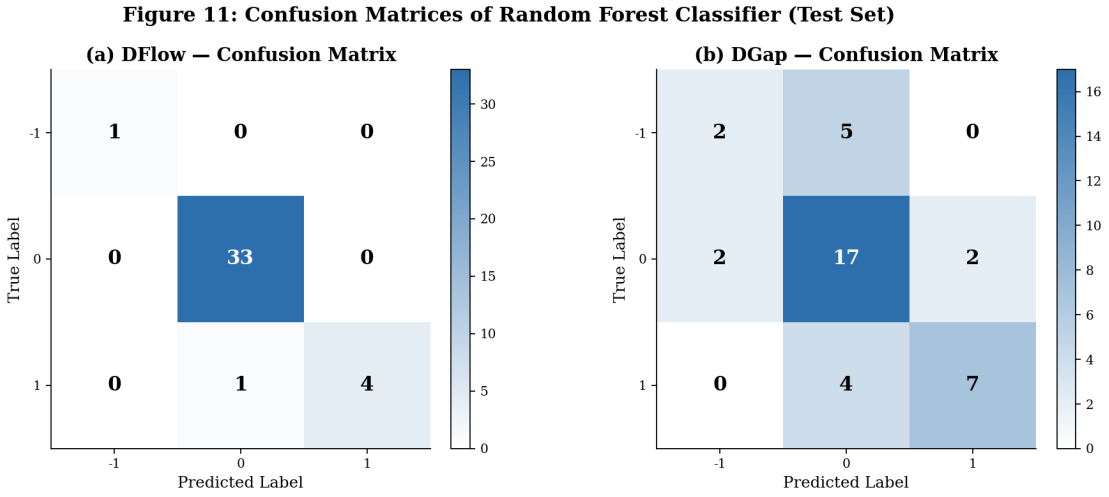


图 11 随机森林分类器在测试集（39 个样本）上的混淆矩阵。图 (a) 为 DFlow 混淆矩阵，图 (b) 为 DGap 混淆矩阵；行对应真实类别，列对应预测类别，颜色深浅反映频次高低；各单元格内的数字为对应频次。

从表12和图11(a) 可知，DFlow 的测试集 Macro-F1 达 95.80%，仅有 1 个样本（$DFlow = +1$ 类）被错误预测为 $DFlow = 0$，总体表现极为优异。这得益于两点：一是测试集中恰好包含了能代表 $DFlow = -1$ 类特征的样本（支持数为 1，且正确识别）；二是 $DFlow = 0$ 类的高频使模型能够充分学习其特征边界。

从表13和图11(b) 可知，DGap 的测试集 Macro-F1 仅为 59.57%，整体低于交叉验证均值，且 $DGap = -1$ 类的召回率只有 29%——在 7 个真实的 $DGap = -1$ 样本中，仅有 2 个被正确识别，其余 5 个被误判为 $DGap = 0$。这一结果揭示了 DGap 分类面临的核心挑战：三类之间存在较大程度的特征重叠，且 $DGap = -1$ 与 $DGap = 0$ 之间的分界在特征空间中并不清晰，即使随机森林这类强分类器也难以完全区分。

8.5 决策边界与概率曲面可视化

为提高预测模型的可解释性，图12基于 DGap 模型中最重要的两个特征（CSM_C_MeanT 与 BSM_B_MeanT）在二维特征子空间中展示了随机森林的决策边界与 $P(DGap = +1)$ 的预测概率轮廓。

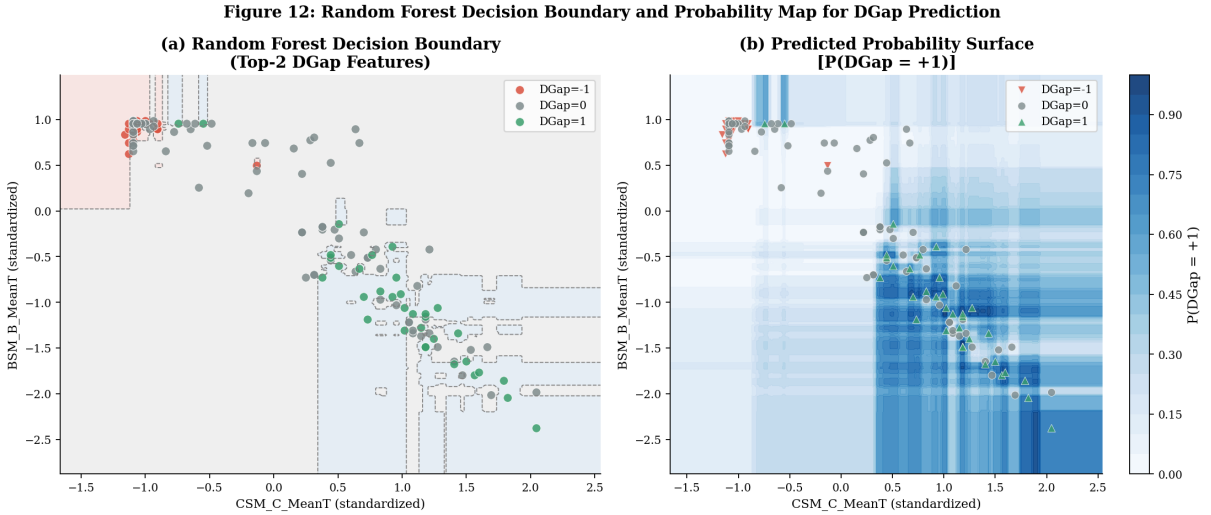


图 12 DGap 预测模型的二维决策边界与概率分布图。图 (a) 为基于前两个最重要特征（标准化后）的随机森林决策边界，背景颜色区分三个预测区域，虚线为决策边界；图 (b) 为同一特征空间中 $P(DGap = +1)$ 的预测概率等高线图，蓝色越深代表预测为 $DGap = +1$ 的概率越高，散点按真实 DGap 类别着色，标记形状区分类别。

从图12(a) 可以观察到：在二维特征空间中，随机森林构建的决策边界呈现出明显的非线性分段特征，$DGap = +1$（绿色区域）主要分布在 CSM_C_MeanT 较大（正向偏移）且 BSM_B_MeanT 较小（负向偏移）的区域；$DGap = -1$（红色区域）则对应 CSM_C_MeanT 较小且 BSM_B_MeanT 较大的区域——这与表10中 DGap 分组均值（CSM 随 DGap 单调增，BSM 随 DGap 单调减）的定量结论高度吻合，说明模型学习到的分类规则与统计分析揭示的物理规律具有良好的一致性。

图12(b) 的概率曲面进一步表明，$DGap = +1$ 的高概率区域（深蓝色）在特征空间中具有较集中的分布，而两类边界区域（中等蓝色）存在显著的过渡带，反映了真实数据中类别重叠的存在。

图13提供了更为直观的三维概率曲面视角。

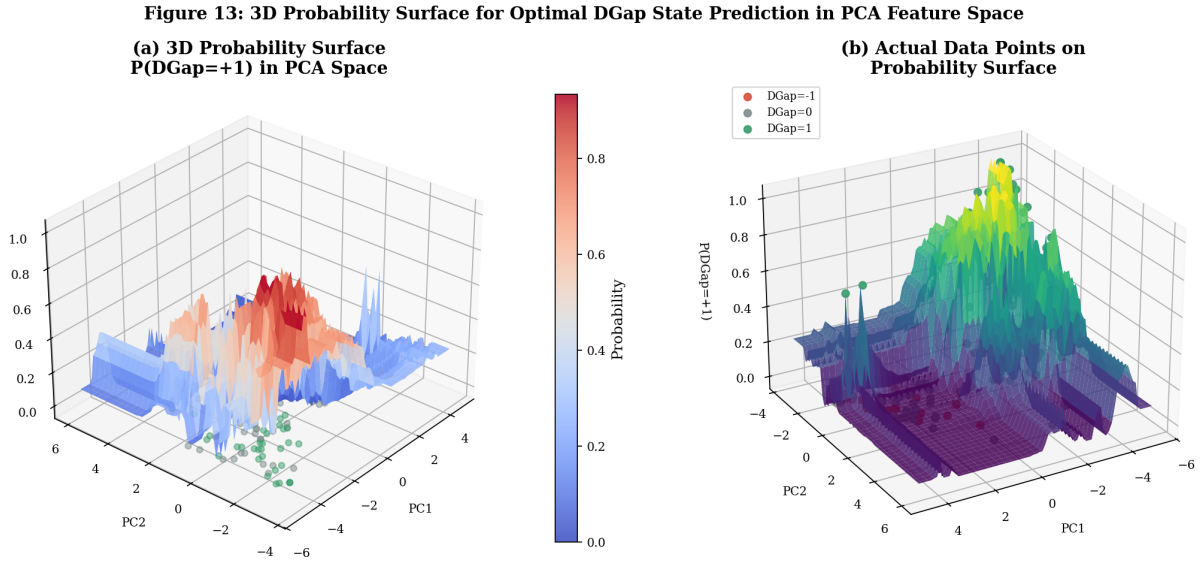


图 13 $P(DGap = +1)$ 在 PCA 二维空间中的三维概率曲面。图 (a) 以 coolwarm 色图展示整体概率曲面形态，底部散点为 154 个样本投影（颜色表示真实 DGap 类别）；图 (b) 将真实数据点映射至对应概率值，直观呈现样本在概率曲面上的分布——绿色点（$DGap = +1$）普遍落在高概率区域，红色点（$DGap = -1$）落在低概率区域，灰色点（$DGap = 0$）分布在中间过渡带。需要特别说明的是，图中所用随机森林模型以 PCA 前两个主成分（PC1, PC2）作为输入特征，仅用于提供一种直观的高维映射下的类别边界拓扑可视化视角。由于 PCA 特征的正交旋转特性与决策树的坐标轴对齐切分逻辑并不天然契合，该 PCA 空间中的随机森林模型并非本文推荐的最终预测模型，其预测性能低于第8节以全量 16 维特征训练的正式模型。

图13的三维曲面展示了 $P(DGap = +1)$ 在 PC1–PC2 空间中的光滑变化趋势：随 PC1 增大，预测概率单调上升，这与前述 PCA 分析中 $DGap = +1$ 类主要分布在 PC1 正半轴的发现一致。曲面中间存在一段概率缓慢变化的过渡区，对应于特征空间中类别重叠的区域，也是模型误判率最高的区间。这一可视化结果有效地将抽象的分类预测结果与数据的内在几何结构联系起来，增强了模型的物理可解释性。

图14进一步从三维视角展示了 DGap 最重要特征的原始散点分布。

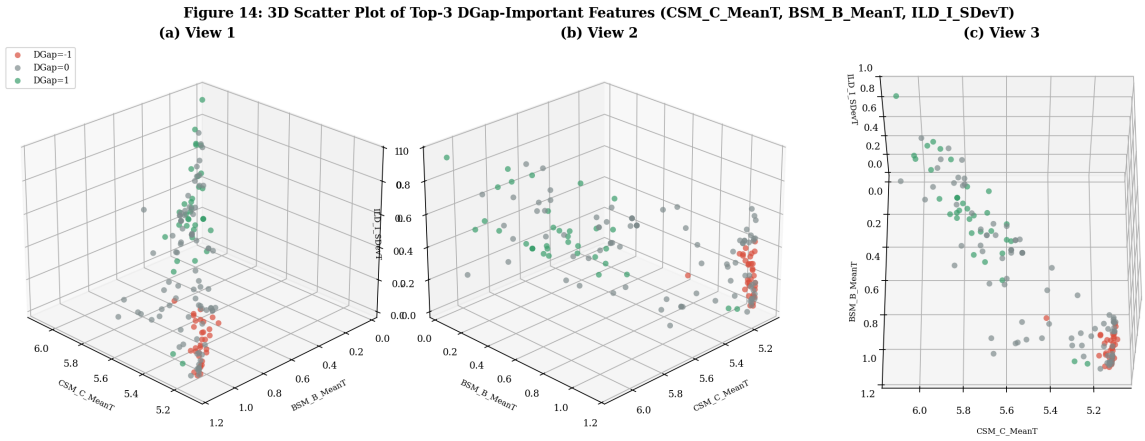


图 14 DGap 预测中最重要三个特征（CSM_C_MeanT、BSM_B_MeanT、ILD_I_SDevT）的三维散点图，从三个不同视角呈现三类 DGap 样本在原始特征空间中的分布结构。红色、灰色、绿色分别对应 $DGap = -1, 0, +1$ 三类。不同视角下类别分离程度的差异说明三类样本的分布在三维空间中具有方向依赖性，选择合适的投影方向是改善分类性能的重要途径。

从图14可以看出，$DGap = -1$（红色）与 $DGap = +1$（绿色）在三维特征空间中具有较好的分离性，而 $DGap = 0$（灰色）则分布较为分散，与其他两类存在不同程度的重叠。这一现象与分类报告中 $DGap = 0$ 的精确率（0.65）低于 $DGap = +1$（0.78）的结果一致：中性状态（$DGap = 0$）在特征空间中并非一个紧凑的聚类，而是呈现弥散分布，导致分类边界难以精确定位。

8.6 实际生产应用的进一步考虑

尽管本文所建立的双模型分类预测框架在给定数据集上取得了较好效果，但若要将其应用于实际电火花加工的在线控制，还需要从以下几个方面进行深化研究和工程实现：

(1) **样本规模与工况覆盖。**当前数据集仅 154 个样本，且主要集中在 $DFlow = 0$ 的工况下，数据的多样性有限。建议系统采集涵盖不同工件材料、电极形状、峰值电流、脉冲宽度等工艺参数组合下的数据，建立更全面的训练库，从而提升模型在多工况下的泛化能力。

(2) **时序动态特性建模。**现有数据为独立的截面样本，未显式包含时序信息，而真实加工过程中脉冲特征具有连续演化的动态特性。本文在交叉验证阶段隐式采用了样本独立同分布（i.i.d.）的假设，但 EDM 实际上是一个强时间依赖的动态过程，前一时刻的间隙状态会直接影响后一时刻的排屑与放电稳定性。若未来能够获取带时间戳的连续脉冲数据，应采用时间序列交叉验证（Time Series Split）以避免随机洗牌带来的时间穿越，并进一步引入滑动时间窗口特征聚合、隐马尔可夫模型或长短时记忆网络（LSTM）等方法，构建更符合真实物理演进规律的动态预测闭环。

(3) **在线测量噪声与传感器漂移。**实际加工环境中的振动、电磁干扰和传感器老化会引入显著的测量噪声。在部署模型前，需要设计鲁棒的信号预处理流程（如卡尔曼滤波、小波降噪等），并在模型训练时引入数据增强或对抗噪声样本以提高抗扰性。

(4) **控制代价与安全约束。**模型的输出是调节方向的建议，而实际调节幅度、调节频率和响应时间均受设备机械特性和安全规范约束。在闭环控制系统中，还需要在模型输出与执行器之间加入速率限制器、幅度约束和安全监控层，防止模型误判导致的工件损坏或设备故障。

(5) **模型在线更新与知识迁移。**随着加工工况的变化或设备磨损，历史数据训练的模型可能出现性能退化。可考虑引入在线学习机制，利用新采集的少量标注样本对模型进行增量更新；或采用迁移学习方法，将在丰富数据工况下训练的模型迁移至数据稀缺的新工况，降低重新标注的成本。

9 模型评价与总结

9.1 模型优点

(1) **多方法交叉验证，结论可靠性高。**本文围绕”特征—控制变量”关系，综合使用 Pearson 相关分析（线性）、随机森林特征重要性（非线性）、PCA（降维可视化）和 LDA（判别可分性）四种方法，多角度得出一致性结论，有效降低了单一方法的偏差风险。

(2) **协同调控方案具有实践可操作性。**通过联合分布分析、卡方检验和 KW 检验三重统计支撑，揭示了 DFlow 与 DGap 的”互斥偏移”规律，并在此基础上提出分层两步决策方案，具有清晰的执行逻辑，适合工厂现场快速实施。

(3) **双模型策略充分利用两个任务的差异特性。**针对 DFlow 与 DGap 分类难度和最优模型各异的特点，采用随机森林与 SVM 并行预测，而非强制使用单一模型，实现了针对性的模型选择。

(4) **模型可解释性得到有效支撑。**通过决策边界可视化、三维概率曲面和箱线图分析，将抽象的分类预测结果与物理意义清晰关联，增强了模型在工程应用中的可信度。

9.2 模型局限

(1) DFlow 类别严重不均衡（类别 -1 仅 5 个样本），导致对该类别的预测性能评估具有较大不确定性，且模型泛化能力受限；

(2) 当前交叉验证前的全局标准化处理在严格意义上存在轻微的数据泄露风险，尽管本文以模型相对性能比较为主要目标，该近似处理对结论排序影响有限，但在工程部署中仍应采用基于训练集独立拟合的 Pipeline 方案；

(3) 模型目前将 $\{-1, 0, +1\}$ 处理为无序的多分类目标，而在实际 EDM 物理过程中，这三个状态具有严格的序数特征。当真实值为 -1 而误判为 $+1$ 时，其工程风险显著高于误判为 0。未来可进一步引入序数回归（Ordinal Regression）或代价敏感学习（Cost-sensitive Learning），对跨越极性的误判赋予更高惩罚；

(4) 所有分析基于静态截面数据，未显式建模脉冲特征的时序动态，与真实在线控制场景存在一定差距；

(5) 复合控制指标 S 的有效性依赖于" 互斥偏移" 规律在不同加工工况下的普适性，且其线性加和映射在一般情形下存在状态混叠风险，需要更多实验数据加以验证；

(6) 模型评价完全依赖离线数据，未经过真实加工闭环控制的验证，实际部署效果尚需工程实践进一步检验。

10 结论

本文针对电火花加工过程中两个关键控制变量 DFlow 和 DGap 的量化关系分析、协同调控方案设计以及最优参数预测三个问题，基于 154 组加工样本和 16 个脉冲特征参数，构建了完整的" 统计分析—协同建模—分类预测" 三层次建模框架。主要研究结论如下：

(1) **关于量化关系（问题一）**：DGap 对 C 类与 B 类均值时间特征最为敏感，其中 CSM_C_MeanT（$r = 0.6693$）、BSM_B_MeanT（$r = -0.6434$）和 CLM_C_MeanT（$r = 0.6302$）是最强的线性相关特征；随机森林重要性分析将 CSM_C_MeanT（14.91%）、BSM_B_MeanT（11.25%）和 ILD_I_SDevT（8.82%）识别为 DGap 预测的核心特征。DFlow 的主要判别特征为 ASM_A_MeanT（13.67%）和 ALM_A_MeanT（13.09%），其重要性主要通过非线性交互体现。PCA 分析显示，前三个主成分累计解释方差达 78.07%，原始特征的主要信息高度浓缩于 B/C 类均值特征的对立变化方向与 A 类特征的波动方向。特征间存在 9 对强相关对（$|r| > 0.8$），层次聚类将其归为 3 个主要特征群。

(2) **关于协同调控（问题二）**：DFlow 与 DGap 之间线性相关性极弱（$r = -0.005$，$p = 0.950$），但卡方检验表明其联合分布具有显著的结构性约束（$\chi^2 = 24.734$，$p < 0.001$）。联合频次表揭示的" 互斥偏移" 规律——即两者不同时偏离中性状态——是协同调控方案的核心依据。定义复合控制指标 $S = DFlow + DGap$，Kruskal–Wallis 检验表明全部 16 个脉冲特征对 S 均极显著可分，据此设计的" 一级确定复

合档位、二级选择单变量执行”两步决策方案，能够在不损失加工质量判断能力的前提下，将二维调控问题有效简化为一维三档决策，具有实际工程应用价值。

(3) **关于预测模型（问题三）**：在五类候选模型中，DFlow 预测以随机森林最优，5 折交叉验证 Macro-F1 达 89.02%（标准差 3.93%）；DGap 预测以 RBF 核 SVM 最优，Macro-F1 达 70.55%（标准差 3.54%）。最终采用双模型并行预测策略，分别对两个控制变量选用各自最优模型。测试集评估显示，DFlow 的 Macro-F1 达 95.80%，DGap 的 Macro-F1 为 59.57%，后者性能相对较低的原因在于 $DGap = -1$ 与 $DGap = 0$ 类之间的特征重叠较大，属于分类任务的固有困难，可通过扩充样本和引入时序特征进一步改善。

综上，本文建立的分析框架能够较为系统地揭示电火花加工脉冲特征与关键控制变量之间的定量映射规律，所提出的协同调控方案和双模型预测框架既具有统计上的严谨性，也具有工程实践上的可操作性，可为电火花加工智能化工艺决策系统的研发提供参考。

参考文献

[1] 姜启源, 谢政, 叶俊. 数学模型（第 5 版）[M]. 北京: 高等教育出版社, 2018.

[2] 周志华. 机器学习 [M]. 北京: 清华大学出版社, 2016.

[3] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1): 5–32.

[4] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273–297.

[5] Jolliffe I T, Cadima J. Principal component analysis: a review and recent developments[J]. Philosophical Transactions of the Royal Society A, 2016, 374(2065): 20150202.

[6] Fisher R A. The use of multiple measurements in taxonomic problems[J]. Annals of Eugenics, 1936, 7(2): 179–188.

[7] Kruskal W H, Wallis W A. Use of ranks in one-criterion variance analysis[J]. Journal of the American Statistical Association, 1952, 47(260): 583–621.

[8] Ho K H, Newman S T. State of the art electrical discharge machining (EDM)[J]. International Journal of Machine Tools and Manufacture, 2003, 43(13): 1287–1300.

[9] 刘义, 李明, 张涛. 电火花加工过程脉冲分类与状态识别方法研究 [J]. 中国机械工程, 2019, 30(12): 1412–1419.

[10] Pedregosa F, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825–2830.

AI 使用情况报告

所用 AI 工具名称和版本： Antigravity（基于 Claude Opus 4.6，Google DeepMind，使用日期：2026-03-31）

具体使用目的和环节：

(1) 辅助整理赛题要求并拆解三个子问题的建模思路；

(2) 辅助在原有绘图代码（code_ver1.py）基础上生成用于计算论文关键数值的补充代码（code_ver2.py）；

(3) 辅助将统计输出结果、图表及建模逻辑整合为规范的 LaTeX 学术论文格式；

(4) 对各章节文字表述进行学术规范化润色。

关键交互记录（概述）： 主要围绕以下问题开展多轮交互：（1）" 根据给定代码和图表结构，为论文补充具体数值输出代码"；（2）" 按北京理工大学数模论文规范，撰写完整 LaTeX 格式的 B 题论文"；（3）" 将所有 14 张图插入正文并大幅扩充各章节论述文字，补充公式推导与图表说明"。

采纳和人工修改情况： AI 工具生成的代码逻辑、表格数据与文字表述均经过参赛队人工核查与修订，所有数值来源均可追溯至程序实际运行结果；论文的核心建模思路、方案设计与物理解释由参赛队独立完成并最终确认。AI 工具生成的内容在参考文献中已按规范标注。

A 支撑材料文件列表

(1) 原始数据文件：202601B 题数据.xlsx；

(2) 题目文件：2026 年北京理工大学数学建模竞赛第一级赛题.docx；

(3) 图表生成与分析代码：code_ver1.py（图表生成）、code_ver2.py（数值计算）；

(4) 图像输出文件：outputs 文件夹下 Fig1_Data_Overview.png 至 Fig14_3D_Probability_Surface.png 共 14 张图；

(5) 论文 LaTeX 源文件：paper_B.tex、paper_B_v2.tex。

B 数值计算代码说明

code_ver2.py 在 code_ver1.py（图表生成代码）的基础上，新增了以下数值计算模块（其余图表生成代码保持不变）：

(1) 数据集基本统计（类别分布、样本数）；

(2) 16 个特征的描述性统计（均值、标准差、最小值、最大值）；

(3) 所有特征与 DFlow、DGap 的 Pearson 相关系数及显著性；

(4) 特征间强相关对筛选（$|r| > 0.8$ 的特征对）；

(5) PCA 方差贡献率及各主成分的前三大载荷特征；

(6) 随机森林特征重要性完整排序（DFlow 和 DGap 两个模型）；

(7) 5 折交叉验证五类模型的 Macro-F1 均值与标准差；

(8) 测试集随机森林的详细分类报告与混淆矩阵（DFlow 和 DGap）；

(9) DFlow–DGap 联合状态频次分布表；

(10) Kruskal–Wallis 检验（特征 vs 复合指标 S）完整结果；

(11) DFlow 与 DGap 的 Pearson、Spearman 相关检验及卡方独立性检验；

(12) LDA 判别轴 LD1 各类均值与标准差；

(13) 按 DGap 分组的各特征均值对比及 Kruskal–Wallis 检验。